

南 开 大 学

本 科 生 毕 业 论 文 （ 设 计 ）

中文题目： 面向遮蔽攻击的对抗性训练

外文题目： Adversarial Training against Occlusion Attacks

学 号： 2111170

姓 名： 丁柏慧

年 级： 2022 级

学 院： 软件学院

系 别： 软件工程

专 业： 软件工程

完成日期： 2026 年 4 月

指导教师： 王靖 副教授

关于南开大学本科生毕业论文（设计）的声明

本人郑重声明：所呈交的学位论文，是本人在指导教师指导下，进行研究工作所取得的成果。除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人创作的、已公开发表或没有公开发表的作品内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。本学位论文原创性声明的法律责任由本人承担。

学位论文作者签名：

年 月 日

本人声明：该学位论文是本人指导学生完成的研究成果，已经审阅过论文的全部内容，并能够保证题目、关键词、摘要部分中英文内容的一致性和准确性。

学位论文指导教师签名：

年 月 日

摘 要

深度神经网络在图像分类等任务中取得了优异性能，但其对对抗样本的高度敏感引发了安全性担忧。现有对抗性训练方法主要针对 L_p 范数约束下的梯度攻击进行防御，对遮蔽类攻击的研究相对匮乏。本文围绕基于像素重要性的遮蔽攻击及其对抗性训练方法展开研究。首先实现了基于原始梯度显著性图与积分梯度两种像素重要性计算方法的遮蔽攻击，并分别设计了遮蔽块参数固定与遮蔽块参数自适应两种攻击策略；进而提出了将遮蔽攻击与 PGD 梯度攻击相结合的混合对抗性训练方法（Mixed Adversarial Training, Mix AT）。在 MNIST 数据集与 LeNet-5 模型上完成了九种防御策略与七类攻击的系统实验。结果表明：自适应遮蔽攻击的攻击强度可超越 PGD 与 C&W 等主流梯度攻击；仅以单一类型攻击训练的模型对训练外攻击防御能力严重退化；Mix AT 在干净准确率、梯度攻击防御与遮蔽攻击防御之间取得了良好平衡。

关键词：对抗性训练，显著性图，梯度积分，遮蔽攻击

Abstract

Deep neural networks have achieved remarkable performance in tasks such as image classification, yet their vulnerability to adversarial examples raises serious security concerns. Most existing adversarial training methods focus on gradient-based attacks under L_p -norm constraints, while defenses against occlusion attacks remain relatively underexplored. This thesis investigates pixel importance-based occlusion attacks and the corresponding adversarial training methods. We first implement occlusion attacks built on two pixel importance estimation methods—gradient saliency maps and Integrated Gradients(IG)—and design both fixed and adaptive occlusion strategies. We then propose a mixed adversarial training method (Mixed Adversarial Training, Mix AT) that combines occlusion attacks with PGD gradient attacks. Systematic experiments are conducted on the MNIST dataset with LeNet-5, evaluating nine defense strategies against seven types of attacks. The results show that adaptive occlusion attacks can surpass mainstream gradient attacks such as PGD and C&W in attack strength; models trained with a single type of attack suffer severe degradation against unseen attacks; Mix AT achieves a favorable balance among clean accuracy, robustness to gradient attacks, and robustness to occlusion attacks.

Key Words: Adversarial Training, Saliency Maps, Integrated Gradients, Occlusion Attacks

目 录

第一章 绪论	1
第一节 研究背景和意义	1
第二节 国内外研究现状	2
1.2.1 对抗样本攻击研究现状	2
1.2.2 对抗性防御研究现状	3
1.2.3 像素重要性分析方法研究现状	4
第三节 研究的关键问题	4
1.3.1 遮蔽攻击的设计与实现	5
1.3.2 对抗性训练策略的构建	5
1.3.3 防御性能的评估与影响因素分析	5
第四节 论文的主要工作	5
第五节 论文组织结构	6
第二章 相关理论与技术背景	8
第一节 神经网络基础	8
2.1.1 卷积神经网络	8
2.1.2 LeNet-5 网络结构	9
2.1.3 损失函数与优化	10
第二节 对抗样本与对抗攻击	11
2.2.1 对抗样本的定义	11
2.2.2 基于梯度的对抗攻击方法	11
2.2.3 基于遮蔽的对抗攻击	13
第三节 对抗性训练	13
2.3.1 对抗性训练的基本框架	13
2.3.2 主要对抗性训练方法	14
2.3.3 对抗性训练的局限性	14
第四节 像素重要性分析方法	15
2.4.1 原始梯度显著性图方法	15
2.4.2 IG 方法	16

第五节 本章小结	16
第三章 基于像素重要性图的遮蔽攻击与对抗性训练方法	18
第一节 问题定义与总体框架	18
3.1.1 问题的形式化定义	18
3.1.2 方法总体框架	18
第二节 基于像素重要性的关键区域定位	19
3.2.1 Saliency Map 计算	19
3.2.2 关键像素区域的选择策略	19
3.2.3 梯度积分方法	20
第三节 基于原始梯度显著性图 (Saliency Map) 的参数固定遮蔽攻击	21
3.3.1 算法设计	21
第四节 基于原始梯度显著性图 (Saliency Map) 的参数自适应遮蔽攻击	22
3.4.1 算法设计	22
第五节 基于梯度积分 (IG) 的遮蔽攻击	22
第六节 对抗性训练策略	24
3.6.1 基于遮蔽攻击的对抗性训练	24
3.6.2 混合对抗性训练策略	24
3.6.3 训练参数与实现细节	25
第七节 本章小结	27
第四章 实验与结果分析	29
第一节 实验环境与数据集	29
4.1.1 实验环境	29
4.1.2 手写数字数据集	29
4.1.3 基础模型	30
第二节 评估指标与实验设置	30
4.2.1 评估指标	30
4.2.2 攻击类型设置	31
4.2.3 防御策略设置	31
第三节 遮蔽攻击效果评估	33
4.3.1 基于原始梯度 (Saliency Map) 的遮蔽攻击效果分析	33
4.3.2 基于梯度积分 (IG) 的遮蔽攻击效果分析	37
4.3.3 攻击效果可视化	38
4.3.4 固定遮蔽与自适应遮蔽的机制差异分析	57

第四节 对抗性训练防御效果对比	59
4.4.1 综合对比结果	59
4.4.2 关键发现	60
4.4.3 遮蔽攻击与梯度攻击的相互抵消趋势	62
4.4.4 两种像素重要性计算方法的可视化对比与像素重要性集中度量化	63
第五节 参数敏感性分析	64
4.5.1 遮蔽区域数参数分析	64
4.5.2 遮蔽半径参数分析	64
4.5.3 遮蔽颜色参数分析	67
4.5.4 训练轮数分析	67
第六节 迁移攻击鲁棒性分析	68
4.6.1 白盒攻击与迁移攻击对比	68
第七节 本章小结	70
第五章 总结与展望	71
第一节 工作总结	71
第二节 研究局限性	72
第三节 未来研究方向	72
参考文献	73
致 谢	76

第一章 绪论

人工智能的研究历史可追溯至二十世纪中叶，该领域经历了多次高潮与低谷。在 2006 年，Hinton 等人提出的深度学习方法 [1] 引发了新一轮研究热潮。深度学习之所以能够推动人工智能技术实现质的飞跃，关键在于其在视觉感知、语言理解等复杂任务上展现出的卓越能力，部分场景下甚至超越了人类表现 [2]。然而，这一看似强大的技术体系却存在一个致命弱点：对对抗性样本的高度敏感。对抗性样本通过在原始数据上叠加精心设计的细微扰动，可使深度神经网络产生置信度极高但完全错误的判断 [3]。Szegedy 等人于 2014 年的实证研究表明，包括当时最先进深度神经网络在内的多种机器学习模型均难以抵御此类攻击 [3]。

第一节 研究背景和意义

近年来，深度学习技术在计算机视觉领域取得了举世瞩目的突破性进展 [2]。以卷积神经网络为代表的深度模型在图像分类、目标检测、语义分割等核心任务上的表现已全面超越传统方法，甚至在部分基准测试中达到乃至超越人类水平 [4, 5]。深度学习模型深刻改变着各行各业的技术格局。

然而，2014 年 Szegedy 等人的开创性研究首次揭示了深度神经网络中普遍存在的对抗样本现象 [3]：通过在原始输入图像上叠加人眼几乎无法察觉的微小扰动，便可以使分类能力极强的深度模型以极高置信度输出完全错误的预测结果。如图 1.1 所示，原始图像经过细微扰动处理后得到对抗样本。对于人眼观察者而言，两幅图像视觉上完全一致，均呈现“熊猫”的形象。然而深度神经网络的判断却截然不同：模型对原始输入能够正确分类，却对对抗样本给出了 99.3% 置信度的“长臂猿”这一错误预测。

这一发现动摇了深度学习系统可靠性高的固有印象，凸显了其固有的脆弱性。后续研究进一步表明，对抗样本的威胁已从数字仿真环境扩展至现实物理




图 1.1 对抗性攻击样本示例

世界：Eykholt 等人验证了在交通标志上施加特定扰动可诱导自动驾驶系统做出错误决策 [6]，Kurakin 等人进一步证明打印出的对抗样本经手机拍摄后仍能欺骗模型 [7]，而医学影像诊断系统中的微弱扰动则可能导致严重误诊 [8]。这些安全问题表明，开展深度模型对抗鲁棒性研究对于实现人工智能技术的可信部署具有重要意义。

面对对抗样本的挑战，学术界提出了多种防御思路，其中对抗性训练 [9] 被广泛认为是目前最有效的防御范式。该方法使用对抗性样本进行训练，使得模型增强对扰动的鲁棒性。

第二节 国内外研究现状

1.2.1 对抗样本攻击研究现状

对抗样本攻击方法的研究伴随着深度学习的发展持续演进，形成了从简单到复杂、从数字域到物理域的多元化攻击体系。

在基于梯度的白盒攻击方面，Goodfellow 等人提出的快速梯度符号法 (FGSM) [10] 是最早的高效攻击算法之一，通过沿损失函数梯度方向施加一步扰动实现攻击，计算代价低但攻击成功率有限。Madry 等人将攻击问题形式化为约束优化问题，提出的投影梯度下降攻击 (PGD) [9] 通过多步迭代逼近最优对抗扰动，被公认为 L_p 范数约束下最强的一阶攻击方法，至今仍是鲁棒性研究的基准参照。Croce 与 Hein 提出的 AutoAttack[11] 将多种互补攻击策略集

成为标准化评估框架，有效规避了单一攻击方法评估的局限性，已成为对抗鲁棒性基准评测的通行标准。

在更贴近物理世界的攻击方面，Brown 等人提出的对抗补丁攻击 (Adversarial Patch) [12] 通过在图像的局部矩形区域叠加显著可见的对抗图案实现攻击，对遮蔽类攻击场景具有直接的启示意义。Eykholt 等人进一步证明，在交通标志上物理粘贴特定图案可稳定欺骗自动驾驶视觉系统 [6]，将对抗攻击的威胁从数字仿真推向真实部署场景。在黑盒攻击方面，Tramèr 等人揭示了对抗样本的跨模型可迁移性 [13]，表明在代理模型上生成的对抗扰动可有效迁移至未知目标模型，从而实现无需访问目标模型梯度的黑盒攻击，大幅降低了现实攻击的实施门槛。

1.2.2 对抗性防御研究现状

对抗性防御方法的研究与攻击方法的进化相互促进，形成了攻防博弈的持续演进格局。

对抗性训练是目前被广泛认可的最有效防御方法。Madry 等人提出的标准对抗性训练 (PGD-AT) [9] 在每轮训练迭代中以 PGD 生成的对抗样本替换干净样本进行训练，显著提升了模型对梯度攻击的鲁棒性，奠定了对抗性训练的基础范式。然而，PGD-AT 的计算开销巨大，制约了其在大规模任务上的应用。Shafahi 等人提出的 Free-AT[14] 通过“免费”复用梯度信息同步更新模型参数与对抗扰动，将训练代价降低至与标准训练相近的水平。Wong 等人提出的 Fast-AT[15] 采用随机初始化的 FGSM 攻击替代多步 PGD，在损失较小的精度代价下大幅缩短了训练时间。

在其他防御路径方面，Papernot 等人提出的防御蒸馏方法 [16] 通过知识蒸馏平滑模型的输出分布，降低对梯度信息的敏感性以缓解梯度攻击的威胁。Cohen 等人提出的随机平滑认证防御 (Certified Defense) [17] 通过对输入施加高斯噪声并统计预测分布，为模型鲁棒性提供可证明的理论保证，是目前为数不多具有严格理论背书的防御方法。Müller 等人研究了标签平滑正则化在对抗鲁棒性提升中的作用 [18]，证明了正则化手段对模型泛化鲁棒性的积极影响。

然而，综观现有防御研究，绝大多数工作的训练信号仍局限于 L_p 范数约束

下的梯度攻击，对以遮蔽为代表的语义驱动型攻击的防御研究严重不足。这一现状导致经过标准对抗性训练的模型在面对遮蔽攻击时防御能力大幅下降，亟需专门的防御方法加以应对。

1.2.3 像素重要性分析方法研究现状

像素重要性分析（Pixel Importance Analysis）方法旨在解释深度神经网络的决策过程，通过识别对预测结果具有关键影响的输入特征区域，为模型可解释性研究提供重要工具，同时也为基于语义特征的对抗攻击提供了方法论支撑。

原始梯度显著性图（Saliency Map）由 Simonyan 等人率先提出 [19]，其核心思想是将网络输出对输入的梯度绝对值作为各像素重要性的度量。该方法计算简洁，仅需一次反向传播即可获得全图的重要性评分，是计算效率最高的像素重要性度量方法之一。Sundararajan 等人提出的梯度积分（Integrated Gradients, IG）[20] 在梯度显著性图的基础上引入了公理化约束，通过沿基线到输入的路径对梯度进行积分，满足灵敏性与实现不变性等理论性质，像素重要性分析精度显著优于原始梯度方法，但代价是需要多次前向与反向传播，计算开销远高于原始梯度显著性图。Selvaraju 等人提出的梯度加权类激活映射（Grad-CAM）[21] 利用卷积特征图的梯度生成类别区分性热力图，能够在不改变网络结构的前提下直观呈现模型的视觉关注区域，在网络可解释性可视化领域得到了广泛应用。

上述像素重要性分析方法具有重要的攻击应用潜力：通过识别模型判断的关键像素区域，可以有针对性地在这些高显著性位置施加遮蔽扰动，从而以最小的扰动面积实现最大化的攻击效果。本文同时实现了基于 Saliency Map 与 IG 两种像素重要性计算方法的遮蔽攻击，系统对比了两种方法在攻击效果、计算效率及对抗训练中的差异。实验表明，IG 遮蔽攻击在像素重要性分析精度上更优，攻击强度更高，但计算代价约为 Saliency Map 的数十倍。

第三节 研究的关键问题

遮蔽攻击作为对抗攻击的一种重要形式，目前相关研究相对匮乏。本文将着重于基于像素重要性图的遮蔽攻击及其对抗性训练方法的研究，从以下三个

方面具体展开：遮蔽攻击的设计与实现，对抗性训练策略的构建，防御性能的评估与影响因素分析。

1.3.1 遮蔽攻击的设计与实现

遮蔽攻击的核心在于识别图像中对模型判断起关键作用的区域，并在该区域施加遮蔽扰动。本文实现了两种像素重要性计算方法来生成显著性图：基于 IG 的方法和基于 Saliency Map 的方法。在此基础上，本文设计了遮蔽块参数固定攻击和遮蔽块参数自适应攻击两种攻击变体，并对两种方法的攻击效果进行对比分析，为后续防御研究提供攻击样本来源。

1.3.2 对抗性训练策略的构建

对抗性训练被广泛认为是最有效的防御方法。然而，现有对抗性训练方法主要针对 L_p 范数约束下的梯度攻击设计，对遮蔽攻击的防御能力不足。本文需要设计一种针对遮蔽攻击的对抗性训练策略，同时兼顾模型对干净样本的识别准确率。此外，本文还提出了混合对抗性训练策略，将遮蔽攻击与 PGD 攻击相结合，以提升模型在多类型攻击场景下的泛化防御能力。

1.3.3 防御性能的评估与影响因素分析

对抗性训练策略实现后，对其防御性能的评估与分析同样重要。本文需要建立合理的评估指标，对所提出的防御策略进行系统测试。在此基础上，还需要分析攻击参数（如遮蔽区域大小、遮蔽块数量）对防御性能的影响，以及不同训练策略之间的效果差异，从而为遮蔽攻击防御领域的后续研究提供参考。

第四节 论文的主要工作

针对 1.3 节中提出的问题，本文使用不同像素重要性计算方法设计了遮蔽攻击方法，并提出了相应的对抗性训练策略。在 MNIST 数据集上对所提方法进行了实验验证，分析了不同参数设置对攻防性能的影响。本文的主要工作如下：

1) 介绍了显著性图与像素重要性分析方法的基本原理，同时实现了基于 Saliency Map 和 IG 两种像素重要性计算方法的遮蔽攻击。在此基础上，分别设

计了遮蔽块参数固定攻击和遮蔽块参数自适应攻击两种攻击变体，系统对比了两种像素重要性计算方法在攻击效果与计算效率上的差异。

2) 基于 LeNet-5 神经网络模型，实现了所提出的遮蔽攻击算法。通过像素重要性图定位图像中对模型判断起关键作用的像素区域，在这些区域施加遮蔽块，从而干扰模型的分类判断。

3) 设计了针对遮蔽攻击的对抗性训练策略，并提出将遮蔽攻击与梯度攻击相结合的混合对抗性训练方案（Mixed Adversarial Training, Mix AT）。在每轮训练迭代中同时引入两类对抗样本，使模型在保持对梯度类攻击鲁棒性的同时，提升对遮蔽类攻击的防御能力。

4) 对所提方法进行了系统的实验评估。在 MNIST 数据集上对九种防御策略（涵盖 Saliency Map 像素重要性与 IG 两类遮蔽训练）在七类攻击下进行了对比测试，分析了遮蔽参数对攻击效果的影响。实验验证了原始梯度显著性遮蔽攻击与梯度攻击在混合训练模型上呈现抵消效应 [22]。

第五节 论文组织结构

本文共分为五章，各章节内容如下：

第一章：绪论。介绍深度学习安全性研究的背景与意义，系统梳理对抗样本攻击、对抗性防御以及显著性图与像素重要性分析方法的国内外研究现状，指出研究的关键问题并概述本文的主要工作，最后给出论文组织结构。

第二章：相关理论与技术基础。介绍本文所涉及的核心技术原理，包括深度神经网络的基本结构与训练原理、对抗样本的定义与威胁模型、常见对抗攻击方法的数学表述，以及显著性图与像素重要性分析方法的理论基础，为后续章节的方法设计提供理论支撑。

第三章：基于像素重要性图的遮蔽攻击与对抗性训练方法。详细阐述本文提出的方法体系，包括基于 Saliency Map 的固定遮蔽攻击算法设计、自适应遮蔽攻击的逐样本早停机制，以及将遮蔽攻击与 PGD 攻击相结合的混合对抗性训练策略的完整实现方案。

第四章：实验与结果分析。介绍实验环境配置、数据集选取与评估指标设

定，对多种防御策略在攻击类型下的鲁棒性进行系统对比分析，并开展攻击参数敏感性分析与迁移攻击鲁棒性验证实验，深入讨论所提方法的有效性及局限性。

第五章：总结与展望。总结本文的主要工作与核心结论，分析现有研究的局限性，并对未来可能的研究方向进行展望。

第二章 相关理论与技术背景

本章系统介绍本文研究所涉及的核心理论与技术背景，主要包括四个方面：深度神经网络的基础知识、对抗样本与对抗攻击方法、对抗性训练框架，以及像素重要性分析方法。这四个方面共同构成了本文方法设计与实验分析的理论基础。

第一节 深度神经网络基础

2.1.1 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）是深度学习领域最具影响力的模型架构之一，在图像分类、目标检测、语义分割等计算机视觉任务中取得了突破性进展 [2, 4]。与传统的全连接神经网络相比，卷积神经网络通过局部连接和权重共享机制，极大地降低了参数量，同时利用卷积核自动提取图像的局部空间特征，具有平移不变性。

卷积神经网络一般由卷积层、池化层和全连接层三类核心层组成。

卷积层是 CNN 的核心组成部分，其基本操作是将一个可学习的滤波器与输入特征图作局部点积运算。设输入特征图为 $\mathbf{X} \in \mathbb{R}^{H \times W \times C_{in}}$ ，卷积核为 $\mathbf{W} \in \mathbb{R}^{k \times k \times C_{in}}$ ，偏置为 b ，则第 (i, j) 位置的输出特征值为：

$$y_{i,j} = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} \sum_{c=1}^{C_{in}} W_{m,n,c} \cdot X_{i+m,j+n,c} + b \quad (2.1)$$

其中 k 为卷积核大小， C_{in} 为输入通道数。通过引入多个卷积层，网络可以提取从低级边缘、纹理到高级语义等特征。

激活函数为神经网络引入非线性变换，使网络能够拟合复杂的非线性函数关系。修正线性单元（Rectified Linear Unit, ReLU）是目前最广泛使用的激活函数，其定义为：

$$\text{ReLU}(x) = \max(0, x) \quad (2.2)$$

ReLU 函数计算简单，能有效缓解深层网络训练中的梯度消失问题，加快训练收敛速度。

池化层对特征图进行下采样，降低特征维度，同时增强模型对微小位置变化的鲁棒性。最大池化操作在每个局部窗口内取最大值，是最常用的池化操作。设池化窗口大小为 $p \times p$ ，步长为 s ，则：

$$z_{i,j} = \max_{0 \leq m < p, 0 \leq n < p} y_{i \cdot s + m, j \cdot s + n} \quad (2.3)$$

全连接层将卷积层提取到的特征展平后进行线性变换，通常位于网络末端，完成最终的分类或回归任务。

2.1.2 LeNet-5 网络结构

LeNet-5 是由 LeCun 等人提出的经典卷积神经网络架构 [23]，最初用于手写数字识别任务，是现代 CNN 架构的重要先驱，其网络结构如图2.1 所示。




图 2.1 LeNet-5 网络结构示意图

本文所使用的 LeNet-5 网络结构在原始架构基础上进行了适配调整，以更好地适配 MNIST 数据集（ 28×28 灰度图像，10 类）。输入图像首先经过均值为 0.1307、标准差为 0.3081 的归一化处理，以加速训练收敛，并提升神经网络泛化能力。第一卷积层使用 $\text{padding} = 2$ 以保持输入的空间尺寸不变，使 28×28 的输入经过 5×5 卷积后仍保持 28×28 ，再经 2×2 最大池化降采样为 14×14 ；

第二卷积层不使用填充，将特征图从 14×14 降至 10×10 ，再经池化降为 5×5 ；最终将 $16 \times 5 \times 5 = 400$ 维特征展平后依次经过三个全连接层，输出 10 类对数概率。网络各层的详细配置如表2.1所示。

表 2.1 本文使用的 LeNet-5 网络结构

层次编号	层类型	配置参数	激活函数	输出尺寸
输入	归一化层	mean=0.1307, std=0.3081	—	$1 \times 28 \times 28$
1	卷积层	$1 \rightarrow 6$, 核 5×5 , padding=2	ReLU	$6 \times 28 \times 28$
1	最大池化	2×2 , stride=2	—	$6 \times 14 \times 14$
2	卷积层	$6 \rightarrow 16$, 核 5×5	ReLU	$16 \times 10 \times 10$
2	最大池化	2×2 , stride=2	—	$16 \times 5 \times 5$
3	全连接层	$400 \rightarrow 120$	ReLU	120
4	全连接层	$120 \rightarrow 84$	ReLU	84
5	全连接层	$84 \rightarrow 10$	—	10

2.1.3 损失函数与优化

在分类任务中，交叉熵损失函数（Cross-Entropy Loss）是最常用的目标函数。设模型对样本 $\mathbf{x}$ 输出的类别概率分布为 $\mathbf{p} = \text{softmax}(f_{\theta}(\mathbf{x}))$ ，真实标签为 y ，则交叉熵损失定义为：

$$\mathcal{L}_{CE}(\mathbf{x}, y; \theta) = -\log p_y = -\log \frac{\exp(f_{\theta}(\mathbf{x})_y)}{\sum_{j=1}^K \exp(f_{\theta}(\mathbf{x})_j)} \quad (2.4)$$

其中 K 为类别总数， $f_{\theta}(\mathbf{x})_j$ 为第 j 类的输出 logit 值。最小化交叉熵损失等价于最大化模型对真实类别的预测概率。

在优化算法方面，本文采用 Adam 优化器 [24] 训练网络参数。Adam 结合了动量（Momentum）和自适应学习率（RMSProp）的优势，对梯度的一阶矩和二阶矩分别进行指数移动平均估计，在不同任务和网络结构上均表现出良好的收敛性和鲁棒性，是深度学习训练中应用最为广泛的优化算法之一。

第二节 对抗样本与对抗攻击

2.2.1 对抗样本的定义

对抗样本 (Adversarial Examples) 是指在原始输入样本 $\mathbf{x}$ 的基础上, 通过添加人眼难以察觉的微小扰动 δ , 生成一个能够欺骗深度神经网络产生错误预测的输入 $\mathbf{x}' = \mathbf{x} + \delta$ 。Szegedy 等人在 2014 年首次系统性地发现并研究了这一现象 [3], 指出即便是在分类任务上表现优异的深度神经网络, 也对精心设计的微小输入扰动极为敏感。

形式化地, 给定分类器 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 和输入样本 $\mathbf{x}$ (真实标签为 y_{true}), 对抗样本 $\mathbf{x}'$ 需同时满足以下两个条件:

$$f(\mathbf{x}') \neq y_{true} \quad \text{且} \quad d(\mathbf{x}, \mathbf{x}') < \epsilon \quad (2.5)$$

其中 $d(\cdot, \cdot)$ 为度量扰动大小的距离函数, $\epsilon > 0$ 为扰动预算 (perturbation budget), 控制对抗扰动的幅度上限。

根据 $d(\cdot, \cdot)$ 的选取方式, 常见的扰动度量有以下三种范数:

L_∞ 范数: $\|\delta\|_\infty = \max_i |\delta_i|$, 约束每个像素的扰动幅度均不超过 ϵ , 是 FGSM、PGD 等主流攻击方法采用的扰动度量, 适合描述分布在全局的均匀微小扰动。

L_2 范数: $\|\delta\|_2 = \sqrt{\sum_i \delta_i^2}$, 约束整体扰动的欧氏距离, 适合描述全局细微的扰动。C&W 攻击等方法以此为优化目标。

L_0 范数: $\|\delta\|_0 = |\{i: \delta_i \neq 0\}|$, 统计被修改的像素数量, 允许对少数像素施加较大幅度的扰动, 其余像素保持不变。 L_0 范数约束与本文所研究的遮蔽攻击 (Occlusion Attack) 类似, 遮蔽攻击同样只对图像的局部区域施加较强干预, 其本质可视为 L_0 范数约束下的一种极端扰动形式。

2.2.2 基于梯度的对抗攻击方法

FGSM 攻击

快速梯度符号法 (Fast Gradient Sign Method, FGSM) 由 Goodfellow 等人提出 [10], 是最具代表性的单步对抗攻击方法。FGSM 利用损失函数关于输入的梯度方向构造对抗扰动, 其生成公式为:

$$\mathbf{x}' = \mathbf{x} + \varepsilon \cdot \text{sign}(\nabla_{\mathbf{x}} \mathcal{L}(f(\mathbf{x}), y)) \quad (2.6)$$

其中 $\text{sign}(\cdot)$ 为符号函数, ε 为扰动步长。FGSM 沿使损失函数增大最快的方向对每个像素施加大小为 ε 的扰动, 一步生成对抗样本, 计算效率极高, 但由于单步近似粗糙, 攻击强度相对有限。

PGD 攻击

投影梯度下降攻击 (Projected Gradient Descent, PGD) 由 Madry 等人提出 [9], 是 FGSM 的多步迭代扩展, 也是目前最为重要的对抗攻击基准之一。PGD 在 ε -球约束集内反复执行梯度上升步骤, 并在每步之后将扰动投影回约束集:

$$\mathbf{x}^{(t+1)} = \Pi_{\mathcal{B}_\varepsilon(\mathbf{x})} \left(\mathbf{x}^{(t)} + \alpha \cdot \text{sign}(\nabla_{\mathbf{x}} \mathcal{L}(f(\mathbf{x}^{(t)}), y)) \right) \quad (2.7)$$

其中 α 为每步步长, $\Pi_{\mathcal{B}_\varepsilon(\mathbf{x})}$ 表示投影到以 $\mathbf{x}$ 为中心、半径为 ε 的 L_∞ 球上的投影算子, 初始扰动 $\mathbf{x}^{(0)}$ 通常在约束集内随机初始化。PGD 通过多步迭代能够更充分地搜索对抗扰动空间, 攻击强度显著高于 FGSM, 是评估模型鲁棒性的标准基准攻击。

C&W 攻击

Carlini 和 Wagner 提出的 C&W 攻击 [25] 将对抗样本生成转化为连续优化问题, 通过最小化以下目标函数来寻找扰动幅度尽可能小的高置信度对抗样本:

$$\min_{\delta} \|\delta\|_2 + c \cdot g(\mathbf{x} + \delta) \quad (2.8)$$

其中 $g(\cdot)$ 是以分类置信度为基础构造的攻击目标函数, 当 $\mathbf{x} + \delta$ 被错误分类时取负值, $c > 0$ 为平衡扰动幅度与攻击成功率的超参数。C&W 攻击能够在 L_2 约束下生成肉眼极难察觉的高质量对抗样本, 常被用作攻击强度的参照基准, 可绕过许多基于梯度掩盖的防御方法。

2.2.3 基于遮蔽的对抗攻击

与基于 L_p 范数约束的梯度攻击方法不同，基于遮蔽的对抗攻击（Occlusion-based Adversarial Attack）通过在图像的局部区域施加大幅度修改（如将像素值设为固定颜色、纯黑或噪声块）来欺骗分类器，其本质是对少数像素实施“局部大幅扰动”而非“全局均匀小幅扰动”。这类攻击的核心思想在于：并非所有像素对模型决策的贡献都相同——模型倾向于依赖少数关键区域做出判断，若这些关键区域被遮蔽或替换，模型极易产生错误预测。

基于遮蔽的对抗攻击与物理世界中的真实威胁场景高度契合。Brown 等人提出的对抗性贴片（Adversarial Patch）[12] 通过在图像中放置一块可打印的对抗性图案，无论贴片放置在何位置，均能使分类器产生目标误分类，且该方法在物理打印环境下仍具有可迁移性。Eykholt 等人 [6] 进一步将遮蔽攻击应用于道路标志识别场景，通过在停车标志上粘贴特定图案，成功使自动驾驶系统的视觉识别模型产生严重误判，揭示了此类攻击在安全关键领域的现实威胁性。

基于遮蔽攻击的上述特点，本文结合显著性图方法，设计了针对关键语义区域的遮蔽攻击策略，并以此为基础构建对抗性训练方法，具体内容将在第 3 章详细阐述。

第三节 对抗性训练

2.3.1 对抗性训练的基本框架

对抗性训练（Adversarial Training）是目前被认为最有效的对抗防御方法之一，其核心思想是在模型训练过程中引入对抗性样本进行训练，使模型通过接触多样化的对抗扰动来增强自身鲁棒性。

对抗性训练的优化目标可形式化为一个 min-max 鞍点优化问题 [9]：

$$\min_{\theta} \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} \left[\max_{\delta \in \mathcal{S}} \mathcal{L}(f_{\theta}(\mathbf{x} + \delta), y) \right] \quad (2.9)$$

其中 $\mathcal{D}$ 为训练数据分布， $\mathcal{S}$ 为允许的扰动集合（如 L_{∞} 球 $\mathcal{B}_{\epsilon}$ ）， θ 为网络参数。该双层优化问题包含两个嵌套的优化过程：

内层最大化：对每个训练样本 $(\mathbf{x}, y)$ ，在扰动约束集 $\mathcal{S}$ 内求解使损失最大化的对抗扰动 δ^* ，等价于在当前模型参数下寻找最强的攻击；

外层最小化：使用内层攻击生成的对抗样本更新模型参数 θ ，使模型对最坏情况下的对抗扰动具有较低损失，从而提升鲁棒性。

Madry 等人从鞍点优化角度对该框架进行了理论分析，并证明使用 PGD 攻击近似求解内层最大化问题，能够有效提升模型的 L_∞ 鲁棒性 [9]。

2.3.2 主要对抗性训练方法

PGD 对抗性训练 (PGD-AT) 与变体

PGD 对抗性训练 (PGD-AT) 是最经典的对抗性训练方法，在训练中，先通过多步 PGD 攻击生成当前样本的对抗样本，再以这些对抗样本计算损失并更新模型参数。该方法防御效果显著，但由于每个训练步骤需要执行多次前向和反向传播来生成对抗样本，训练开销是标准训练的数倍至数十倍。

为降低对抗性训练的计算开销，Wong 等人提出了基于随机初始化 FGSM 的快速对抗性训练方法 (FGSM-AT) [15]，通过单步 FGSM 攻击代替多步 PGD 生成对抗样本，将训练成本降低至接近标准训练的水平；Shafahi 等人提出的 Free 对抗性训练 [14] 则通过在单次前向-反向传播中同时更新扰动参数和模型参数，进一步提高了训练效率，在保持较好鲁棒性的同时大幅削减了计算成本。

2.3.3 对抗性训练的局限性

尽管对抗性训练已取得显著进展，但其在实际应用中仍面临以下主要局限：

攻击类型专一性：现有对抗性训练方法通常针对特定攻击类型（如 L_∞ -PGD）进行优化，对训练过程中未见的攻击类型（如 L_2 攻击、遮蔽攻击）往往缺乏有效防御。模型在特定威胁模型下的鲁棒性提升并不能自动泛化到其他攻击形式，这是对抗性训练泛化性不足的核心问题，也是本文研究混合对抗性训练策略的重要动机。

干净准确率下降：引入对抗样本训练后，模型在干净测试样本上的准确率通常会出现不同程度的下降，即存在“鲁棒性—准确率权衡”（robustness-accuracy trade-off）现象。这一问题在实际部署中尤为突出，因为系统不仅需要抵御对抗

攻击，也必须在正常输入上保持高精度。

训练计算开销大：以 PGD-AT 为代表的对抗性训练方法需要执行多步迭代攻击，导致训练时间远高于标准训练，在大规模数据集和复杂网络结构下，这一问题尤为突出，限制了对抗性训练的实际应用范围。

第四节 像素重要性分析方法

像素重要性分析（Pixel Importance Analysis）方法旨在量化输入特征对神经网络预测结果的贡献程度，并可视化模型的“注意力”分布。这类方法在模型可解释性研究中具有重要地位，同时也为本文的遮蔽攻击提供了关键区域定位的依据。

2.4.1 原始梯度显著性图方法

原始梯度显著性图（Vanilla Gradient Saliency Map, Saliency Map）由 Simonyan 等人提出 [19]，是最基础也最直观的像素重要性分析方法。其核心思想是：模型预测对某一输入像素的梯度绝对值越大，说明该像素对预测结果的影响越大，即该像素越“显著”。

形式化地，设 $f_c(\mathbf{x})$ 为模型关于类别 c 的输出分数，则输入 $\mathbf{x}$ 的显著性图定义为：

$$\mathbf{S}(\mathbf{x}) = \left| \frac{\partial f_c(\mathbf{x})}{\partial \mathbf{x}} \right| \quad (2.10)$$

其中 $|\cdot|$ 表示逐元素取绝对值。 $\mathbf{S}(\mathbf{x})$ 的每个元素对应输入图像中相应像素的重要性得分，整体构成一张与输入图像等尺寸的显著性热力图，高值区域对应模型决策贡献最大的像素位置。

Saliency Map 的主要优势在于计算效率极高：只需对输入进行一次前向传播和一次反向传播即可获得完整的显著性图，无需对模型结构进行任何修改。在需要对每个训练样本实时计算 Saliency Map 的对抗性训练场景中，这一特性尤为重要。

2.4.2 IG 方法

梯度积分（Integrated Gradients, IG）由 Sundararajan 等人提出 [20]，是一种在理论上更为严格的像素重要性分析方法。IG 的核心思想是沿从基线输入 $\mathbf{x}^{(0)}$ （通常为全零图像）到目标输入 $\mathbf{x}$ 的路径上对梯度进行积分，从而计算每个特征对预测变化的累积贡献：

$$\text{IG}_i(\mathbf{x}) = (x_i - x_i^{(0)}) \cdot \int_0^1 \frac{\partial f_c(\mathbf{x}^{(0)} + \alpha(\mathbf{x} - \mathbf{x}^{(0)}))}{\partial x_i} d\alpha \quad (2.11)$$

其中 x_i 和 $x_i^{(0)}$ 分别为目标输入和基线输入第 i 个特征的值， $\alpha \in [0, 1]$ 为插值参数。在实际计算中，连续积分通常被离散化为 m 步黎曼和近似：

$$\text{IG}_i(\mathbf{x}) \approx (x_i - x_i^{(0)}) \cdot \frac{1}{m} \sum_{k=1}^m \frac{\partial f_c(\mathbf{x}^{(0)} + \frac{k}{m}(\mathbf{x} - \mathbf{x}^{(0)}))}{\partial x_i} \quad (2.12)$$

积分梯度（IG）方法满足两个重要的公理性质：

敏感性公理（Sensitivity）：若两个输入仅在某一特征上不同，且模型输出不同，则该特征的像素重要性分析值应非零，确保像素重要性分析结果能够真实反映特征对预测的贡献；

实现不变性公理（Implementation Invariance）：对于任意两个功能等价的网络（即对所有输入具有相同输出），其像素重要性分析结果应相同，保证像素重要性分析方法的一致性，不受具体网络实现细节的影响。

第五节 本章小结

本章系统梳理了本文研究所依赖的核心理论与技术背景。首先介绍了卷积神经网络的基本组成与工作原理，阐述了 LeNet-5 的具体网络结构及其在 MNIST 任务上的适配方案，并介绍了交叉熵损失函数与 Adam 优化器。其次，详细介绍了 FGSM、PGD、C&W 等主流基于梯度的对抗攻击方法，以及基于遮蔽的对抗攻击。第三，从 min-max 优化的视角阐述了对抗性训练的基本框架，介绍了 PGD-AT、FGSM-AT 和 Free 训练等主流方法，并分析了对抗性训练在攻击

泛化性、干净准确率和计算开销方面的主要局限。最后，介绍了 Saliency Map 和 IG 两种像素重要性分析方法。

第三章 基于像素重要性图的遮蔽攻击与对抗性训练方法

第一节 问题定义与总体框架

3.1.1 问题的形式化定义

设图像分类模型为 $f_{\theta} : \mathcal{X} \rightarrow \mathcal{Y}$ ，其中 θ 为模型参数， $\mathcal{X} \subseteq [0, 1]^{C \times H \times W}$ 为输入空间， $\mathcal{Y} = \{1, 2, \dots, K\}$ 为标签空间。对于输入样本 $(x, y) \in \mathcal{X} \times \mathcal{Y}$ ，标准训练的目标是最小化经验风险：

$$\min_{\theta} \mathbb{E}_{(x, y) \sim \mathcal{D}} [\mathcal{L}(f_{\theta}(x), y)] \quad (3.1)$$

其中 $\mathcal{L}$ 为交叉熵损失， $\mathcal{D}$ 为训练数据分布。

3.1.2 方法总体框架

本文的方法由三个核心模块构成：

1. **关键区域定位**：利用像素重要性图定位模型决策的关键像素区域，生成二值掩码 M 。
2. **遮蔽攻击生成**：在关键区域定位的基础上，分别设计遮蔽块参数固定攻击和遮蔽块参数自适应攻击。
3. **对抗性训练**：将遮蔽攻击生成的对抗样本引入训练循环，并进一步提出混合对抗性训练策略，将遮蔽攻击与 PGD 攻击 [9] 相结合，提升模型对多类型攻击的泛化防御能力。

相比现有 L_p 范数方法，本文方法的核心差异在于攻击的构造方式： L_p 攻击在全图范围内施加微小扰动，而遮蔽攻击仅修改少数关键区域，扰动幅度大但范围集中。这一差异使得遮蔽攻击在语义层面更贴近真实世界的遮挡干扰，同时也要求防御模型具备更强的局部鲁棒性。

第二节 基于像素重要性的关键区域定位

3.2.1 Saliency Map 计算

Saliency Map 由 Simonyan 等人 [19] 提出，其核心思想是利用模型对输入的一阶梯度信息衡量每个像素对预测结果的重要程度。给定分类模型 f_θ 、输入图像 $x \in \mathbb{R}^{C \times H \times W}$ 及真实类别 y ，梯度显著性图定义为：

$$S(x, y) = \left| \frac{\partial f_y(x)}{\partial x} \right| \quad (3.2)$$

其中 $f_y(x)$ 表示模型对类别 y 的输出得分 (logit)， $|\cdot|$ 表示逐元素取绝对值。显著性值越高的像素，其微小变化对模型输出的影响越大，因此被视为模型决策的关键特征。

在实现层面，算法1给出了完整的计算流程。

算法 1 Saliency Map 计算

输入： 分类模型 f_θ ，输入图像 x ，真实标签 y

输出： 显著性图 $S \in \mathbb{R}^{C \times H \times W}$

- 1: 启用输入梯度追踪: $x.requires_grad \leftarrow \text{True}$
 - 2: 前向传播: $\text{output} \leftarrow f_\theta(x)$
 - 3: 提取目标类别得分: $\text{scores} \leftarrow \text{output}[y]$ (按真实标签索引)
 - 4: 反向传播: 计算 $\partial \text{scores} / \partial x$ (通过自动微分)
 - 5: 取绝对值: $S \leftarrow |\partial \text{scores} / \partial x|$
 - 6: **return** S
-

算法1仅需一次前向传播与一次反向传播，时间复杂度与标准训练的单步梯度计算相当。

3.2.2 关键像素区域的选择策略

得到显著性图 S 后，需从中提取最关键的空间区域以生成遮蔽掩码。本文采用基于卷积的邻域求和策略，其设计动机如下：单像素遮蔽在视觉上几乎不可见且对模型影响有限，而连续的方形区域遮蔽能够同时覆盖高显著性像素及其空间邻域，更符合真实场景中的遮挡形态。

邻域显著性聚合。对显著性图进行空间邻域求和，使用全一卷积核 $\mathbf{1}_{k \times k}$ (边

长为 k 的方形核，所有权重为 1)：

$$S_{\text{sum}}(i, j) = \sum_{(p, q) \in \mathcal{N}_k(i, j)} S(p, q) \quad (3.3)$$

其中 $\mathcal{N}_k(i, j)$ 表示以 (i, j) 为中心的 $k \times k$ 邻域。 S_{sum} 的峰值位置对应显著性最集中的空间区域。在实现上，式(3.3)等价于一次二维卷积操作：

$$S_{\text{sum}} = \text{Conv2d}(S, \mathbf{1}_{k \times k}, \text{padding} = \lfloor k/2 \rfloor) \quad (3.4)$$

Top- K 位置选取。将 S_{sum} 展平为一维向量，选取数值最大的 K 个位置索引 $\{(i_1, j_1), \dots, (i_K, j_K)\}$ ：

$$\{(i_t, j_t)\}_{t=1}^K = \underset{(i, j) \in [H] \times [W]}{\text{top-}K} S_{\text{sum}}(i, j) \quad (3.5)$$

掩码膨胀。在每个选中的位置 (i_t, j_t) 处，将以其为中心的 $k \times k$ 方形区域在掩码 M 中置为 1：

$$M(p, q) = 1 \quad \text{若} \quad \exists t : \max(|p - i_t|, |q - j_t|) \leq \lfloor k/2 \rfloor \quad (3.6)$$

遮蔽施加。最终对抗样本通过如下公式生成：

$$x' = x \odot (1 - M) + c \cdot M \quad (3.7)$$

其中 $c = 0$ 对应黑色遮蔽， $\odot$ 为逐元素乘积。此公式在遮蔽区域用颜色 c 替换原始像素，在非遮蔽区域保持原始像素不变。

3.2.3 梯度积分方法

梯度积分 (Integrated Gradients, IG) [20] 是一种理论性质更完备的像素重要性分析方法，其通过从基准图像 x_0 (通常为全黑图像) 到输入 x 的路径积分

计算像素重要性值:

$$\text{IG}_i(x, y) = (x_i - x_{0,i}) \cdot \int_0^1 \frac{\partial f_y(x_0 + \alpha(x - x_0))}{\partial x_i} d\alpha \quad (3.8)$$

在实践中, 积分通过 Riemann 近似以 $n_{\text{steps}} = 50$ 步离散化, 需要 50 次前向与反向传播, 且依赖 Captum 等外部库。

第三节 基于原始梯度显著性图 (Saliency Map) 的参数固定遮蔽攻击

3.3.1 算法设计

参数固定遮蔽攻击是本文实现的基础攻击方法, 其核心思想是对样本施加统一参数的遮蔽操作。给定超参数 top_k (关键区域数量) 和 kernel_size (遮蔽窗口尺寸), 算法对每个样本独立定位最显著的 top_k 个邻域聚合峰值, 并在这些位置施加固定尺寸的方形遮蔽。

算法2给出了基于原始梯度显著性图 (Saliency Map) 的参数固定遮蔽攻击的完整流程。

算法 2 参数固定遮蔽攻击

输入: 分类模型 f_θ , 输入图像 $x \in \mathbb{R}^{C \times H \times W}$, 标签 y , 关键区域数 top_k , 卷积核尺寸 kernel_size , 遮蔽颜色 c

输出: 对抗样本 $x' \in \mathbb{R}^{C \times H \times W}$

- 1: 显著性计算: $S \leftarrow |\partial f_y(x) / \partial x|$ (Saliency Map)
 - 2: 邻域聚合: $S_{\text{sum}} \leftarrow \text{Conv2d}(S, \mathbf{1}_{\text{kernel_size} \times \text{kernel_size}})$
 - 3: **for** 每个样本 $i = 1, \dots, B$ **do**
 - 4: 在 $S_{\text{sum}, i}$ 中选取数值最大的 top_k 个位置 $\{(i_t, j_t)\}_{t=1}^{\text{top}_k}$
 - 5: 初始化掩码 $M_i \leftarrow \mathbf{0}^{H \times W}$
 - 6: **for** 每个选中位置 (i_t, j_t) **do**
 - 7: 将 (i_t, j_t) 为中心的 $\text{kernel_size} \times \text{kernel_size}$ 区域置为 1
 - 8: **end for**
 - 9: **end for**
 - 10: 施加遮蔽: $X' \leftarrow X \odot (1 - M) + c \cdot M$
 - 11: 像素截断: $X' \leftarrow \text{clamp}(X', 0, 1)$
 - 12: **return** X'
-

参数固定遮蔽攻击可直接控制遮蔽区域的数量，`kernel_size` 控制每个遮蔽块的尺寸，两者共同决定遮蔽的总覆盖面积约为 $\text{top}_k \times \text{kernel_size}^2$ 。在参数合理的情况下，遮蔽面积相对于图像总面积的比例较小，但由于遮蔽位置精确命中显著性峰值，攻击效果显著。

然而，参数固定遮蔽攻击存在一个潜在局限：对不同难度的样本施加相同强度的遮蔽，可能对简单样本过度扰动，而对困难样本扰动不足。为此，本文进一步提出自适应遮蔽攻击。

第四节 基于原始梯度显著性图 (Saliency Map) 的参数自适应遮蔽攻击

3.4.1 算法设计

参数自适应遮蔽攻击是本文实现的改进攻击方法。其核心思想是通过迭代方式逐步遮蔽最关键的区域，以最小的遮蔽面积实现有效攻击。算法引入两个关键参数：最大遮蔽区域数 N 和最大遮蔽半径 R 。

算法3详细描述了自适应原始梯度显著性图的完整流程。

该算法维护每个样本的成功标志 `success[i]`，一旦样本 i 的预测被成功翻转，后续迭代不再对其施加额外扰动。这确保了每个样本只受到恰好足够的最小遮蔽，避免不必要的过度扰动。同时算法在两个维度上逐步增加攻击强度：遮蔽区域数 $n \in \{1, \dots, N\}$ 控制覆盖的关键区域数量；遮蔽半径 $r \in \{1, \dots, R\}$ 控制每个遮蔽块的空间范围。对于每个 (n, r) 组合，遮蔽总面积约为 $n \times (2r + 1)^2$ 。通过先遍历 n 再遍历 r 的搜索顺序，优先以更多区域、较小范围的遮蔽实现攻击。

第五节 基于梯度积分 (IG) 的遮蔽攻击

为对比不同像素重要性计算方法对遮蔽攻击效果及对抗性训练性能的影响，本文在基于梯度显著性图 (Saliency Map) 的遮蔽攻击方法之外，同时实现了基于梯度积分 (IG) 的遮蔽攻击方法。IG 遮蔽攻击与 Saliency Map 遮蔽攻击共享相同的掩码生成框架，Top-K 位置选取与掩码膨胀仅在像素重要性计算步骤进行

算法 3 参数自适应遮蔽攻击

输入: 分类模型 f_θ , 输入图像 $x \in \mathbb{R}^{C \times H \times W}$, 标签 y , 最大遮蔽区域数 N , 最大遮蔽半径 R , 遮蔽颜色 c

输出: 对抗样本 $x' \in \mathbb{R}^{C \times H \times W}$

```

1: 显著性计算:  $S \leftarrow |\partial f_y(x)/\partial x|$ 
2: 按显著性降序对像素位置排序, 得到索引序列  $\text{idx}$ 
3: 预计算累积掩码: 构造所有  $(n, r)$  组合的累积掩码
4: for  $r = 1$  to  $R$  do
5:   for  $i = 0$  to  $N - 1$  do
6:     以第  $i$  显著像素为中心, 创建半径为  $r$  的方形掩码块  $M_{\text{block}}(i, r)$ 
7:     累积:  $\text{mask}(i+1, r) \leftarrow \text{clamp}(\text{mask}(i, r) + M_{\text{block}}(i, r), 0, 1)$ 
8:   end for
9: end for
10: 初始化:  $x' \leftarrow x.\text{clone}()$ ,  $\text{success} \leftarrow \text{False}$ 
11: 渐进遮蔽与提前终止:
12: for  $n = 1$  to  $N$  do
13:   if  $\text{success} = \text{True}$  then break
14:   end if
15:   for  $r = 1$  to  $R$  do
16:     if  $\text{success} = \text{True}$  then break
17:     end if
18:      $x' \leftarrow (1 - \text{mask}(n, r)) \cdot x + \text{mask}(n, r) \cdot c$ 
19:      $x' \leftarrow \text{clamp}(x', 0, 1)$ 
20:      $\hat{y} \leftarrow f_\theta(x').\text{argmax}()$ 
21:     if  $\hat{y} \neq y$  then  $\text{success} \leftarrow \text{True}$ 
22:     end if
23:   end for
24: end for
25: return  $x'$ 

```

替换：将式(3.2)中的梯度显著性图 $S(x,y) = |\partial f_y(x)/\partial x|$ 替换为 IG 图。

具体而言，基于 IG 的参数固定遮蔽攻击流程为：首先使用 Captum 库 [26] 的 IntegratedGradients 模块 ($n_{\text{steps}} = 50$) 计算每个像素的 IG 值，随后执行与 Saliency Map 遮蔽攻击相同的邻域聚合（式(3.3)）、Top- K 选取与掩码膨胀操作，最终生成遮蔽对抗样本。基于 IG 的参数自适应遮蔽攻击则在计算替换为 IG 的基础上，沿用自适应遮蔽攻击（算法3）的逐样本提前终止与二维渐进搜索机制，实现基于 IG 的自适应遮蔽。

两种 IG 遮蔽攻击的主要参数与原始梯度显著性图保持一致：参数固定遮蔽攻击取 $k = 9$ ，参数自适应遮蔽攻击取 $N = 5$ 、 $R = 3$ 。IG 的积分步数取 $n_{\text{steps}} = 50$ ，基线图像取全零图像 ($x_0 = \mathbf{0}$)。

第六节 对抗性训练策略

3.6.1 基于遮蔽攻击的对抗性训练

将遮蔽攻击嵌入对抗性训练框架，形成基于遮蔽攻击的对抗性训练。其训练目标为：

$$\min_{\theta} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\mathcal{L}(f_{\theta}(x'), y)], \quad x' = \mathcal{A}_{\text{occ}}(f_{\theta}, x, y) \quad (3.9)$$

其中 $\mathcal{A}_{\text{occ}}$ 为遮蔽攻击方法（参数固定遮蔽攻击或参数自适应遮蔽攻击）。当像素重要性计算方法选用 Saliency Map 时，对应基于 Saliency Map 遮蔽攻击的对抗性训练（Saliency-AT）；当选用 IG 时，对应基于 IG 遮蔽攻击的对抗性训练（IG-AT）。两种像素重要性计算方法均可与参数固定遮蔽攻击或参数自适应遮蔽攻击策略组合。

算法4描述了完整的训练流程。

3.6.2 混合对抗性训练策略

基于遮蔽攻击的对抗性训练能够有效提升模型对遮蔽类攻击的防御能力，但由于训练时仅使用遮蔽攻击样本，模型可能在抵御梯度类攻击（如 FGSM[10]、PGD[9]）方面出现退化。这一现象源于对抗性训练的攻击类型特异性，模型倾

算法 4 基于遮蔽攻击的对抗性训练

输入： 训练集 $\mathcal{D}$, 模型 f_θ , 遮蔽攻击方法 $\mathcal{A}$, 训练轮数 epochs

输出： 鲁棒模型参数 θ^*

```

1: for epoch = 1 to epochs do
2:   for 每个小批量  $(X, Y) \in \mathcal{D}$  do
3:     切换至评估模式:  $f_\theta.\text{eval}()$ 
4:     生成对抗样本:  $X' \leftarrow \mathcal{A}(f_\theta, X, Y)$ 
5:     切换至训练模式:  $f_\theta.\text{train}()$ 
6:     前向传播:  $\text{output} \leftarrow f_\theta(X')$ 
7:     计算损失:  $\mathcal{L} \leftarrow \text{CrossEntropy}(\text{output}, Y)$ 
8:     反向传播并更新参数:  $\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}$ 
9:   end for
10: end for
11: return  $\theta$ 

```

向于拟合训练时所见攻击的扰动分布，对训练时未见的攻击类型泛化能力有限。

为解决上述问题，本文提出混合对抗性训练策略 (Mixed Adversarial Training, Mix AT)，在每次训练迭代中以概率 p 选用遮蔽攻击，以概率 $1 - p$ 选用 PGD 攻击：

$$X' = \begin{cases} \mathcal{A}_{\text{occ}}(f_\theta, X, Y), & \text{以概率 } p \\ \mathcal{A}_{\text{pgd}}(f_\theta, X, Y), & \text{以概率 } 1 - p \end{cases} \quad (3.10)$$

通过混合两类攻击范式，模型在训练过程中同时接触语义遮蔽扰动和 L_∞ 梯度扰动，从而在两类攻击的防御上取得更好的权衡。算法5给出了混合对抗性训练的完整流程。

混合比例 p 是一个重要的超参数，控制两类攻击在训练数据中的比重。当 $p = 1$ 时退化为纯遮蔽攻击对抗性训练，当 $p = 0$ 时退化为纯 PGD 对抗性训练，当 $p = 0.5$ 时两类攻击等权混合。本文实验中取 $p = 0.5$ ，以期在两类防御能力之间取得平衡，具体效果将在第四章实验中验证。

3.6.3 训练参数与实现细节

本文所有训练实验在统一的参数配置下进行，以保证实验结果的可重复性和可比性。表3.1列出了全部训练超参数及其含义。

算法 5 混合对抗性训练 (Mix AT)

输入： 训练集 $\mathcal{D}$ ，模型 f_θ ，遮蔽攻击算子 $\mathcal{A}_{\text{occ}}$ ，PGD 攻击算子 $\mathcal{A}_{\text{pgd}}$ ，混合比

例 $p = 0.5$ ，训练轮数 epochs

输出： 鲁棒模型参数 θ^*

```

1: for epoch = 1 to epochs do
2:   for 每个小批量  $(X, Y) \in \mathcal{D}$  do
3:     采样  $u \sim \text{Uniform}(0, 1)$ 
4:     if  $u < p$  then
5:        $X' \leftarrow \mathcal{A}_{\text{occ}}(f_\theta, X, Y)$ 
      ▷ 遮蔽攻击分支
6:     else
7:        $X' \leftarrow \mathcal{A}_{\text{pgd}}(f_\theta, X, Y)$ 
      ▷ PGD 攻击分支
8:     end if
9:     前向传播:  $\text{output} \leftarrow f_\theta(X')$ 
10:    计算损失:  $\mathcal{L} \leftarrow \text{CrossEntropy}(\text{output}, Y)$ 
11:    反向传播并更新参数:  $\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}$ 
12:   end for
13: end for
14: return  $\theta$ 

```

表 3.1 训练超参数配置

参数	取值	含义描述
epochs	50	训练总轮数
batch_size	256	小批量大小
lr	0.001	初始学习率
optimizer	Adam	优化器类型
PGD ϵ	0.1	PGD 攻击扰动预算 (L_∞ 范数上界)
PGD step_size	0.025	PGD 单步步长
PGD iterations	20	PGD 迭代步数
top_k	9	参数固定遮蔽攻击关键区域数
kernel_size	3	遮蔽窗口边长 (像素)
N	5	参数自适应遮蔽攻击最大遮蔽区域数
R	3	参数自适应遮蔽攻击最大遮蔽半径
ratio p	0.5	混合训练中遮蔽攻击的比例
occlusion_color c	0.0	遮蔽填充颜色 (黑色)

PGD 攻击参数。扰动预算 $\epsilon = 0.1$ 和步长 $\text{step_size} = 0.025$ 基于 L_∞ 范数，像素值归一化到 $[0, 1]$ 。PGD 迭代 20 步，每步沿梯度符号方向移动 step_size ，并投影回 ϵ -球内，具体更新规则为：

$$x_{t+1} = \Pi_{x,\epsilon}(x_t + \text{step_size} \cdot \text{sign}(\nabla_x \mathcal{L}(f_\theta(x_t), y))) \quad (3.11)$$

其中 $\Pi_{x,\epsilon}$ 表示向以原始样本 x 为中心的 L_∞ 范数 ϵ -球的投影操作。

参数固定遮蔽参数。 $\text{top_k} = 9$ 与 $\text{kernel_size} = 3$ 意味着每个样本最多被遮蔽 $9 \times 3^2 = 81$ 个像素。对于 MNIST 的 $28 \times 28 = 784$ 像素图像，遮蔽比例约为 10.3%。

参数自适应遮蔽参数。最大区域数 $N = 5$ 、最大半径 $R = 3$ 定义了二维搜索空间，最大可能的遮蔽面积为 $5 \times (2 \times 3 + 1)^2 = 5 \times 49 = 245$ 像素，约占图像面积的 31.3%。但在实践中，大多数样本以远小于此的遮蔽即可被成功攻击。

第七节 本章小结

本章系统介绍了基于像素重要性图的遮蔽攻击与对抗性训练方法，主要内容可归纳如下。

首先，对研究问题进行了形式化定义，明确了遮蔽攻击相对于传统 L_p 范数攻击的差异性，指出了现有对抗性训练方法在防御遮蔽攻击方面的局限性，并给出了本章方法的总体框架。

其次，详细阐述了基于梯度显著性图的关键区域定位方法。给出了梯度显著性图的定义与计算算法（算法1），介绍了基于卷积邻域聚合的 Top-K 位置选取策略与掩码膨胀方法。在此基础上，实现了基于梯度积分的参数固定 IG 遮蔽攻击与参数自适应 IG 遮蔽攻击，两种 IG 攻击与原始梯度显著性攻击共享相同的掩码生成框架，仅在像素重要性计算步骤进行替换。

第三，实现了参数固定遮蔽攻击（算法2）。该方法为对抗性训练的基础攻击手段。

第四，实现了参数自适应遮蔽攻击（算法3）。通过引入逐样本提前终止策

略和二维渐进搜索机制（遮蔽区域数与遮蔽半径的联合搜索），自适应攻击能够以最小的扰动面积实现有效攻击，在攻击精准性和攻击成功率方面均优于参数固定遮蔽攻击。使用预计算累积掩码进一步提升了算法的运行效率。

最后，设计了两种对抗性训练策略：基于遮蔽攻击的对抗性训练（算法4）和混合对抗性训练（算法5）。训练框架中的遮蔽攻击算子支持梯度显著性图与梯度积分两种像素重要性计算方法，分别对应显著性遮蔽对抗性训练与 IG 遮蔽对抗性训练及其混合变体。混合训练策略通过以概率 $p = 0.5$ 交替使用遮蔽攻击与 PGD 攻击，有效缓解了单一攻击类型训练导致的防御泛化能力不足问题。训练超参数的详细配置见表3.1。

上述方法的实验验证将在第四章展开，包括不同防御策略对多类型攻击的鲁棒性对比、参数敏感性分析等内容。

第四章 实验与结果分析

本章对第三章提出的遮蔽攻击方法及对抗性训练策略进行系统性实验验证。首先介绍实验环境、数据集与评估指标；其次评估遮蔽攻击本身的有效性；随后对九种防御策略进行综合对比，深入分析各策略的防御特点与局限；进一步开展参数敏感性分析与迁移攻击鲁棒性实验；最后对全部实验结果进行综合讨论。

第一节 实验环境与数据集

4.1.1 实验环境

本文实验在如表 4.1 所示的软硬件环境下完成。

表 4.1 实验软硬件环境配置

配置项	配置内容
操作系统	Windows 11
编程语言	Python 3.10
深度学习框架	PyTorch 2.7.1
CUDA 版本	CUDA 11.8
优化器	Adam [24]

4.1.2 手写数字数据集

本文采用 MNIST 手写数字数据集 [27] 作为目标数据集。MNIST 是计算机视觉与对抗鲁棒性研究领域最经典的基准数据集之一，其主要特征如下：训练集包含 60,000 张样本，测试集包含 10,000 张样本；每个样本的图像分辨率为 28×28 像素，单通道灰度图；标签覆盖 0 至 9 共 10 个数字类别；像素值归一化采用均值 0.1307、标准差 0.3081 的标准化处理，即：

$$\hat{x} = \frac{x - 0.1307}{0.3081} \quad (4.1)$$

选用 MNIST 的原因在于：其输入维度适中，模型训练速度较快，有利于开展大规模参数扫描实验；同时该数据集语义结构清晰，便于直观分析遮蔽攻击对关键像素区域的影响。

4.1.3 基础模型

本文以改进后的 LeNet-5 [23] 作为基础分类网络，网络结构详见第二章表 2.1。该网络在标准训练（无对抗扰动）下于 MNIST 测试集上可达 99.0% 的干净准确率，表明基础模型具有充分的分类能力，为后续对抗性训练实验提供了可靠的性能基线。所有防御策略均选用相同的网络架构进行训练，仅在训练目标上加以区分，从而保证对比实验的公平性。

第二节 评估指标与实验设置

4.2.1 评估指标

本文采用以下三项核心指标对模型性能进行全面评估：

干净准确率（Clean Accuracy）：模型在未受任何攻击的测试集上的分类准确率，衡量对抗性训练对正常样本性能的影响，计算方式为：

$$\text{CleanAcc} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[f_{\theta}(x_i) = y_i] \quad (4.2)$$

对抗准确率（Adversarial Accuracy）：模型在对抗样本上的分类准确率，衡量模型抵御特定攻击的能力，是评估防御有效性的核心指标：

$$\text{AdvAcc} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[f_{\theta}(x'_i) = y_i] \quad (4.3)$$

其中 x'_i 为对应攻击方法生成的对抗样本。

攻击成功率（Attack Success Rate, ASR）：定义为对抗准确率的补集，反映攻击对模型的欺骗程度：

$$\text{ASR} = 1 - \text{AdvAcc} \quad (4.4)$$

4.2.2 攻击类型设置

本文共设置七类攻击方法，参数配置如表 4.2 所示。

表 4.2 攻击方法参数配置

攻击方法	关键参数	参数说明
FGSM [10]	$\epsilon = 0.1$	单步梯度符号攻击，扰动在 L_∞ 球内
PGD [9]	$\epsilon = 0.1$, $\alpha = 0.025$, 迭代 20 次	多步投影梯度下降攻击
C&W [25]	$\epsilon = 0.1$, $\alpha = 0.025$, 迭代 20 次, $\kappa = 50$	基于优化的强攻击, κ 控制置信度
基于 Saliency Map 的参数固定 (Fixed-Saliency) 遮蔽攻击	$k = 9$, 卷积核尺寸 3, 填充色 $c = 0$	基于 Saliency Map 的固定 Top- K 参数遮蔽攻击
基于 Saliency Map 的参数自适应 (Adaptive-Saliency) 遮蔽攻击	$N = 5$, $R = 3$, 填充色 $c = 0$	基于 Saliency Map 的迭代遮蔽攻击
基于 IG 的参数固定 (Fixed-IG) 遮蔽攻击	$k = 9$, $n_{\text{steps}} = 50$, 填充色 $c = 0$	基于 IG 的固定 Top- K 参数遮蔽攻击
基于 IG 的参数自适应 (Adaptive-IG) 遮蔽攻击	$N = 5$, $R = 3$, $n_{\text{steps}} = 50$, 填充色 $c = 0$	基于 IG 的迭代遮蔽攻击

其中 FGSM、PGD、C&W 属于梯度类攻击，通过在输入空间施加受约束的像素级扰动来生成对抗样本；Saliency Map 与 IG 遮蔽攻击属于结构性遮蔽攻击，通过遮蔽关键语义区域实现欺骗，不受 L_p 范数约束。两种遮蔽攻击采用不同的像素重要性计算方法定位关键区域：Saliency Map 遮蔽攻击与 IG 遮蔽攻击在攻击精度与计算效率上各有优劣，详见第三章的对比分析。

4.2.3 防御策略设置

本文共设计并评估九种防御策略，覆盖标准训练基线、基于梯度攻击的对抗性训练、基于 Saliency Map 遮蔽攻击的对抗性训练、基于 IG 遮蔽攻击的对抗性训练及混合对抗性训练五大类别，具体如下：

1. **标准训练 (Standard)**: 无对抗扰动, 仅使用干净样本训练, 作为性能基线。
2. **PGD 对抗性训练 (PGD-AT)**: 基于 PGD 对抗样本的对抗性训练 [9], 代表梯度类攻击防御的主流范式。
3. **FGSM 对抗性训练 (FGSM-AT)**: 基于 FGSM 对抗样本的对抗性训练 [10], 计算开销较小的梯度防御方法。
4. **基于 Saliency Map 的参数自适应遮蔽攻击的对抗性训练 (Adaptive-Saliency-AT)**: 基于 Saliency Map 遮蔽攻击的参数自适应 ($N = 5, R = 3$) 的对抗性训练, 训练时每轮对最显著区域施加参数不固定遮蔽块。
5. **基于 Adaptive-Saliency 遮蔽攻击与 PGD 的混合对抗性训练 (Mix AT(Adaptive-Saliency+PGD))**: 以 Adaptive-Saliency 遮蔽攻击与 PGD 攻击共同训练, 平衡遮蔽防御与梯度防御。
6. **基于 IG 的参数固定遮蔽攻击的对抗性训练 (Fixed-IG-AT)**: 基于 Fixed-IG 遮蔽攻击 ($k = 9$) 的对抗性训练, 进行固定遮蔽块参数的训练。
7. **基于 IG 的参数自适应遮蔽攻击的对抗性训练 (Adaptive-IG-AT)**: 基于自适应 IG 遮蔽攻击 ($N = 5, R = 3$) 的对抗性训练, 进行自适应遮蔽训练。
8. **基于 Fixed-IG 遮蔽攻击与 PGD 的混合对抗性训练 (Mix AT(Fixed-IG+PGD))**: 以 Fixed-IG 遮蔽攻击与 PGD 攻击共同训练。
9. **基于 Adaptive-IG 遮蔽攻击与 PGD 的混合对抗性训练 (Mix AT(Adaptive-IG+PGD))**: 以 Adaptive-IG 遮蔽攻击与 PGD 攻击共同训练。

其中策略 6 至 9 与策略 4 至 5 形成基于不同像素重要性计算方法的平行对照: 前者使用 IG 方法, 后者使用 Saliency Map 方法, 两组策略在遮蔽方式 (参数固定/参数自适应) 和训练框架 (基于遮蔽攻击的对抗性训练/基于混合攻击的对抗性训练) 上保持一致, 以系统评估像素重要性计算方法选择对防御性能的影响。

所有策略均在相同的训练设置下进行: 训练轮数 50 个 epoch, 使用 Adam 优化器 [24], 学习率调度一致, 以确保比较的公平性。

第三节 遮蔽攻击效果评估

4.3.1 基于原始梯度 (Saliency Map) 的遮蔽攻击效果分析

为验证本文提出的遮蔽攻击方法的有效性，首先在未经对抗性训练的标准模型（Standard）上评估参数固定遮蔽攻击（以下称为固定遮蔽攻击）和参数自适应遮蔽攻击（以下称为自适应遮蔽攻击）的攻击强度，实验结果如表 4.3 所示。

表 4.3 Saliency Map 遮蔽攻击在标准模型上的攻击效果对比

攻击类型	参数设置	模型准确率 (%)
无攻击（干净样本）	—	99.00
Fixed-Saliency	$k = 3$, kernel_size=3	86.82
Fixed-Saliency	$k = 5$, kernel_size=3	80.99
Fixed-Saliency	$k = 9$, kernel_size=3	71.19
Fixed-Saliency	$k = 15$, kernel_size=3	59.78
Adaptive-Saliency	$N = 3$, $R = 3$	49.45
Adaptive-Saliency	$N = 5$, $R = 3$	34.33
Adaptive-Saliency	$N = 7$, $R = 3$	25.08
Adaptive-Saliency	$N = 10$, $R = 3$	15.95
Adaptive-Saliency	$N = 5$, $R = 2$	49.15
Adaptive-Saliency	$N = 5$, $R = 4$	23.91

实验结果表明，固定遮蔽攻击与自适应遮蔽攻击均能有效降低模型准确率。

从参数敏感性角度分析：（1）固定攻击的 k 参数从 3 增至 15，准确率从 86.82% 降至 59.78%，自适应攻击固定 $R = 3$ 时， N 从 3 增至 10，准确率从 49.45% 降至 15.95%，表明增加遮蔽区域数可提升攻击强度；（2）自适应攻击固定 $N = 5$ 时， R 从 2 增至 4，准确率从 49.15% 降至 23.91%，说明增大遮蔽半径同样能显著提升攻击强度。

Adaptive-Saliency Map 遮蔽攻击（ $N = 5$, $R = 3$ ）在标准模型准确率降低为

34.33%，与 PGD 攻击（33.34%）和 C&W 攻击（33.37%）的攻击强度基本相当。这一结果表明遮蔽攻击在不依赖任何 L_p 范数约束的条件下，仅通过遮蔽少数关键语义区域，即可达到与强梯度攻击相近的欺骗效果，充分说明显著性图 (Saliency Map) 所定位的关键区域确实是模型分类决策的核心依据。

图 4.1 展示了固定遮蔽攻击在标准模型上的可视化效果；图 4.2 和图 4.3 分别展示了自适应遮蔽攻击中迭代次数 N 和遮蔽半径 R 的影响。




图 4.1 Fixed-Saliency 遮蔽攻击效果可视化（标准模型）：不同 k 参数下的攻击结果，红色区域为遮蔽位置，标题显示预测结果、置信度及模型准确率




图 4.2 Adaptive-Saliency 遮蔽攻击效果可视化（标准模型，固定 $R = 3$ ，变化 N ）：蓝色区域为遮蔽位置，标题显示预测结果、置信度及模型准确率




图 4.3 Adaptive-Saliency 遮蔽攻击效果可视化（标准模型，固定 $N = 5$ ，变化 R ）：蓝色区域为遮蔽位置，标题显示预测结果、置信度及模型准确率

4.3.2 基于梯度积分 (IG) 的遮蔽攻击效果分析

为对比不同像素重要性计算方法对遮蔽攻击效果的影响，本节在标准模型上评估基于 IG 的遮蔽攻击强度，实验结果如表 4.4 所示。

表 4.4 IG 遮蔽攻击在标准模型上的攻击效果对比

攻击类型	参数设置	模型准确率 (%)
无攻击（干净样本）	—	99.00
Fixed-IG	$k = 3$, kernel_size=3	58.42
Fixed-IG	$k = 5$, kernel_size=3	42.18
Fixed-IG	$k = 9$, kernel_size=3	28.64
Fixed-IG	$k = 15$, kernel_size=3	18.95
Adaptive-IG	$N = 3$, $R = 3$	28.45
Adaptive-IG	$N = 5$, $R = 3$	16.66
Adaptive-IG	$N = 7$, $R = 3$	12.08
Adaptive-IG	$N = 10$, $R = 3$	9.52
Adaptive-IG	$N = 5$, $R = 2$	32.15
Adaptive-IG	$N = 5$, $R = 4$	11.83

对比表 4.3 中 Saliency Map 遮蔽攻击的结果，IG 遮蔽攻击在标准模型上的攻击强度显著更高。从参数敏感性角度分析：（1）Fixed-IG 遮蔽攻击的 k 参数从 3 增至 15，准确率从 58.42% 降至 18.95%，而同参数的 Fixed-Saliency 遮蔽攻击准确率从 86.82% 降至 59.78%，IG 攻击的效果显著更强；（2）Adaptive-IG 遮蔽攻击固定 $R = 3$ 时， N 从 3 增至 10，准确率从 28.45% 降至 9.52%，而同参数的 Adaptive-Saliency 遮蔽攻击准确率从 49.45% 降至 15.95%；（3）Adaptive-IG 遮蔽攻击固定 $N = 5$ 时， R 从 2 增至 4，准确率从 32.15% 降至 11.83%，同样远低于 Adaptive-Saliency 遮蔽攻击的 49.15% 至 23.91%。

这一结果验证了梯度积分在像素重要性分析精度上的优势，即 IG 通过路径积分（ $n_{\text{steps}} = 50$ 步）计算累积特征重要性，比单点梯度更准确地识别模型决策

的关键像素，从而使遮蔽攻击的定位更为精准。值得注意的是，Adaptive-IG 遮蔽攻击 ($N=5$, $R=3$) 的攻击强度为 16.66%，超过了 PGD 攻击 (33.34%) 和 C&W 攻击 (33.37%)，表明基于精确像素重要性分析的遮蔽攻击在攻击潜力上可超越主流梯度攻击。

4.3.3 攻击效果可视化

为直观展示遮蔽攻击对模型决策的影响，本节给出四类典型可视化：

(1) 标准模型遮蔽攻击可视化。图 4.4 展示了在标准模型上，Adaptive-Saliency 攻击仅遮蔽少量像素即可让模型完全误判，且置信度往往达到 90% 以上，体现了“肉眼难辨但模型误判”的攻击隐蔽性。




图 4.4 标准模型上 Adaptive-Saliency 攻击

(2) 四种攻击对比。图 4.5 展示同一样本在 Fixed-Saliency, Adaptive-Saliency, Fixed-IG 和 Adaptive-IG 四种不同攻击类型的遮蔽攻击下的效果。可观察到 IG 遮蔽攻击由于像素重要性分析更精准，遮蔽位置更集中于笔画核心，Adaptive 遮蔽攻击因早停机制一般使遮蔽量更少。

(3) 多模型遮蔽鲁棒性对比。图 4.6 在 Adaptive-Saliency 攻击下，对比 Standard、PGD-AT、FGSM-AT、Adaptive-Saliency-AT、Adaptive-IG-AT、Mix




图 4.5 标准模型上四种遮蔽攻击对比。图中 $a \rightarrow b(c\%)$ 表示真实类别为 a 、模型预测为 b 且置信度为 $c\%$ ，绿色表示预测正确，红色表示攻击成功

AT(Adaptive-Saliency+PGD)、Mix AT(Adaptive-IG+PGD) 七种模型的攻击效果, 遮蔽位置以红块叠加。可见经过基于遮蔽攻击的对抗训练 (Adaptive-Saliency-AT、Mix AT) 的模型在被同一攻击作用后仍能正确分类, 而 Standard、PGD-AT、FGSM-AT 普遍被攻破, 反映了遮蔽攻击对传统梯度防御方法具有较强的攻击能力, 而针对遮蔽攻击设计的对抗训练策略能有效提升模型的鲁棒性。




图 4.6 Adaptive-Saliency 攻击下七种模型的对比。红块为遮蔽位置; 左侧为真实类别; 各子图中的数字为预测类别, 括号内为置信度, 绿色表示预测正确, 红色表示被攻破

(4) 对抗训练模型上的遮蔽攻击对比。图 4.7 与图 4.8 展示了 PGD-AT 模型上的遮蔽攻击案例, 图 4.9 与图 4.10 展示了 Adaptive-Saliency-AT 模型上的遮蔽攻击案例。可见 PGD-AT 模型仍可被遮蔽攻击攻破; 而 Adaptive-Saliency-AT 模型对同类攻击具备更强鲁棒性。

(5) 不同对抗性训练模型上的像素重要性分析。图 4.11 与图 4.12 给出了




图 4.7 PGD-AT 模型上的 Adaptive-Saliency 攻击案例




图 4.8 PGD-AT 模型上的 Adaptive-IG 攻击案例




图 4.9 Adaptive-Saliency-AT 模型上的 Adaptive-Saliency 攻击案例




图 4.10 Adaptive-Saliency-AT 模型上的 Adaptive-IG 攻击案例

PGD-AT 与 Adaptive-Saliency-AT 模型上的显著性热图与遮蔽位置。可观察到 PGD-AT 的 Saliency 热图较为集中，更加聚焦于笔画区域，而 Adaptive-Saliency-AT 的 Saliency 热图则更分散，攻击所获得的遮蔽位置往往无法起到决定性作用，从而导致攻击失败率上升。




图 4.11 PGD-AT 模型上 Adaptive-Saliency 攻击的显著性与遮蔽位置关系

(6) 四种攻击在对抗训练模型上的差异。图 4.13 ~ 图 4.15 展示了在 PGD-AT、Adaptive-Saliency-AT、Adaptive-IG-AT 上四种遮蔽攻击的可视化对比。结合表 4.7 可知：PGD-AT 在面对遮蔽攻击时鲁棒性显著下降，而 Adaptive-Saliency-AT 与 Adaptive-IG-AT 由于训练时显式接触了显著性遮蔽样本，对所有四种遮蔽攻击均表现出最优防御。

(7) 固定攻击下的多模型对比。图 4.16 与图 4.17 分别展示 Fixed-Saliency




图 4.12 Adaptive-Saliency-AT 模型上 Adaptive-Saliency 攻击的显著性与遮蔽位置关系，可见对抗训练后显著性图聚焦更稳健、攻击命中率明显下降




图 4.13 PGD-AT 模型上四种遮蔽攻击对比。图中 $a \rightarrow b(c\%)$ 表示真实类别、预测类别和置信度，红色表示预测错误，绿色表示预测正确




图 4.14 Adaptive-Saliency-AT 模型上四种遮蔽攻击对比。图中 $a \rightarrow b(c\%)$ 表示真实类别、预测类别和置信度，红色表示预测错误，绿色表示预测正确




图 4.15 Adaptive-IG-AT 模型上四种遮蔽攻击对比。图中 $a \rightarrow b(c\%)$ 表示真实类别、预测类别和置信度，红色表示预测错误，绿色表示预测正确

与 Fixed-IG 攻击下七种模型的对比。Fixed 攻击在多数对抗训练模型上整体弱于 adaptive 攻击。图 4.18 展示了 Adaptive-IG 攻击下的多模型对比，除 Adaptive-Saliency-AT 与 Adaptive-IG-AT 之外，多数模型易仍被攻破，其中 PGD-AT 和 FGSM-AT 出现明显失效。




图 4.16 Fixed-Saliency 攻击下七种模型的对比。左侧为真实类别；各子图中的数字为预测类别，括号内为置信度，颜色表示预测是否正确

(8) 自适应攻击的内部演化过程。图 4.19 与图 4.20 分别展示标准模型上 Adaptive-Saliency 与 Adaptive-IG 攻击在迭代过程中的中间状态。每一行对应一个样本，从左至右展示遮蔽随迭代次数 n 的渐进增长过程，多数样本随着 n 增加更可能被攻破，早停机制有效避免了对易攻击样本的过度遮蔽。

(9) Fixed 与 Adaptive 遮蔽位置叠加对比。图 4.21 与图 4.22 展示在标准模型上、相同 top- k/N 设置下，Fixed 与 Adaptive 选取的遮蔽位置差异：Fixed 选位




图 4.17 Fixed-IG 攻击下七种模型的对比。左侧为真实类别；各子图中的数字为预测类别，括号内为置信度，颜色表示预测是否正确




图 4.18 Adaptive-IG 攻击下七种模型的对比。左侧为真实类别；各子图中的数字为预测类别，括号内为置信度，颜色表示预测是否正确




图 4.19 标准模型上 Adaptive-Saliency 攻击的内部演化。左侧为真实类别；每个中间状态中的数字为预测类别，括号内为置信度




图 4.20 标准模型上 Adaptive-IG 攻击的内部演化。左侧为真实类别；每个中间状态中的数字为预测类别，括号内为置信度

高度集中且彼此重叠（与表 4.5 中 52.10% 重叠率一致）；Adaptive 借助逐次评估将遮蔽分布到更多互补区域，从而以更小的实际像素数完成攻击。图 4.23 与图 4.24 给出 PGD-AT 上的对应对比，可观察到该模型在 Fixed 遮蔽攻击下的遮蔽面积较大。





图 4.21 标准模型：Fixed-Saliency vs Adaptive-Saliency 遮蔽位置对比

图 4.22 标准模型: Fixed-IG vs Adaptive-IG 遮蔽位置对比 (参数 $k=N=5$, $R=3$, kernel=7)




图 4.23 PGD-AT 模型: Fixed-Saliency vs Adaptive-Saliency 遮蔽位置对比




图 4.24 PGD-AT 模型: Fixed-IG vs Adaptive-IG 遮蔽位置对比 (参数 $k = N = 5$, $R = 3$, $\text{kernel} = 7$)

4.3.4 固定遮蔽与自适应遮蔽的机制差异分析

实验发现，固定遮蔽攻击在标准模型上的攻击效果（71.19%）显著弱于自适应遮蔽攻击（34.33%）。

Fixed 遮蔽的”块重叠”问题。固定遮蔽攻击一次性选择显著性卷积响应最强的 $\text{top-}k$ 像素中心，并以固定大小的卷积核为每个中心生成遮蔽块。由于 $\text{top-}k$ 个最显著像素在空间上往往集中分布于数字笔画的相同邻域，它们生成的遮蔽块极易彼此重叠，使得最终的有效遮蔽面积远小于理论上限 $k \times s^2$ 像素。

Adaptive 遮蔽的”逐次评估 + 早停”机制。自适应遮蔽攻击通过 $n = 1 \dots N$ 、 $r = 1 \dots R$ 的渐进式增长，每完成一次遮蔽即通过模型前向传播判断该样本是否被攻击成功；一旦预测改变即停止对该样本的进一步遮蔽。这一机制有两个关键作用：（1）由于半径 r 从 1 开始逐步增大，在小半径阶段不同区域的遮蔽块几乎不重叠；（2）逐样本早停保证了使用最小遮蔽量即攻击成功，对易攻击样本仅需极少遮蔽即终止。

量化验证。以 5 个不同类别的 MNIST 样本为例，统计两种遮蔽策略实际写入图像的像素数（详见图 4.25）：

表 4.5 Fixed 与 Adaptive 遮蔽实际写入像素数的对比（标准模型）

指标	Fixed ($k=9$)	Adaptive ($N=5, R=3$)	说明
理论上限像素数	81	245	不考虑边界与重叠
实际平均遮蔽像素	38.80	47.40	按 5 样本均值统计
重叠/未触达比率	52.10%	—	Fixed 平均一半位置被重叠浪费
单样本最小遮蔽	35	21	Adaptive 早停效率显著
单样本最大遮蔽	45	64	Adaptive 对难样本可加大力度

实验结果显示，固定遮蔽攻击的 9 个 3×3 遮蔽块由于显著像素的空间聚集性发生大面积重叠，平均有效遮蔽面积仅占理论上限的 **47.9%**（38.80/81），而自适应策略借助早停机制以平均 47.40 像素即完成攻击，且各样本之间遮蔽量差异显著（21~64 像素）。这一机制差异表明：

1. **自适应遮蔽攻击比固定遮蔽攻击更有效：**自适应遮蔽攻击实际有效遮蔽面积更大，且每一次新增遮蔽都基于”当前模型仍预测正确”的状态定位关键区域，避免了固定遮蔽一次性选取的盲目性。

2. 固定遮蔽攻击在某些对抗训练模型上出现”迁移强于白盒”的反直觉现象的部分原因：由于固定遮蔽攻击在白盒目标模型上选取的 $\text{top-}k$ 像素高度集中（重叠率超过 50%），有效遮蔽面积严重缩水；而迁移攻击在 Standard 替代模型上选取像素时，因 Standard 的显著性图分布更分散（详见第4.4.4节），重叠率反而较低，迁移到目标模型后实际遮蔽面积更大、攻击更强。




图 4.25 Fixed ($k=9, 3 \times 3$) 与 Adaptive ($N=5, R=3$) 遮蔽机制差异可视化。第二行红色高亮显示固定遮蔽攻击 9 个遮蔽块的累计覆盖次数，亮红色区域为多块重叠位置；第三、四行展示两种策略的最终遮蔽效果与实际像素数。固定遮蔽攻击由于重要像素聚集导致 52.10% 的有效面积被重叠浪费，而自适应遮蔽攻击通过逐次评估与早停以更小代价定位更分散的关键区域。

第四节 对抗性训练防御效果对比

4.4.1 综合对比结果

本节对九种防御策略在全部攻击方法下的防御效果进行系统评估。为便于分析，将实验结果分为梯度类攻击（表 4.6）与遮蔽类攻击（表 4.7）两部分分别呈现。

表 4.6 各防御策略在梯度类攻击下的准确率对比（%）

防御策略	干净样本	FGSM	PGD	C&W
Standard	99.00	79.46	33.34	33.37
PGD-AT	99.30	96.10	94.95	95.05
FGSM-AT	99.20	95.68	90.64	90.83
Adaptive-Saliency-AT(N=5,R=3)	98.73	41.56	4.78	5.73
Mix AT(Adaptive-Saliency+PGD)	98.91	94.51	92.87	92.81
Fixed-IG-AT	95.75	3.24	0.00	0.00
Adaptive-IG-AT	98.48	39.01	0.20	0.24
Mix AT(Fixed-IG+PGD)	98.53	93.50	91.70	91.70
Mix AT(Adaptive-IG+PGD)	98.90	94.01	91.48	91.40

表 4.7 各防御策略在遮蔽类攻击下的准确率对比（%）

防御策略	Fixed-Saliency (k=9)	Adaptive-Saliency (N=5,R=3)	Fixed-IG (k=9)	Adaptive-IG (N=5,R=3)
Standard	71.19	34.33	28.64	16.66
PGD-AT	70.11	30.12	49.17	25.42
FGSM-AT	73.73	33.90	54.14	25.55
Adaptive-Saliency-AT(N=5,R=3)	98.43	94.30	64.74	47.18
Mix AT(Adaptive-Saliency+PGD)	95.48	80.65	80.94	66.98
Fixed-IG-AT	95.11	78.91	97.34	64.23
Adaptive-IG-AT	98.36	92.02	90.42	87.03
Mix AT(Fixed-IG+PGD)	97.34	67.86	84.43	59.23
Mix AT(Adaptive-IG+PGD)	97.30	76.06	87.69	77.50

图 4.26 以柱状图形式直观展示了各防御策略在不同攻击类型下的准确率对比。可以清晰看到，PGD-AT 和 Mix AT 在梯度攻击（FGSM、PGD、C&W）下表现优异，而 Adaptive-Saliency-AT 在自适应遮蔽攻击下防御效果最好，Mix AT 则在两种攻击类型之间实现了平衡。




图 4.26 各防御策略在不同攻击类型下的准确率对比

图 4.27 通过雷达图直观对比了 Adaptive-Saliency-AT 与 Mix AT 的综合防御性能。可以看出，Adaptive-Saliency-AT 在遮蔽攻击防御维度明显占优，而 Mix AT 则在梯度攻击防御维度表现更佳，二者形成了互补的防御特性。

4.4.2 关键发现

综合分析表 4.6 与表 4.7 的实验数据，可以归纳出以下发现：

攻击特异性使单一对抗性训练存在明显的防御盲区。

PGD 对抗性训练（PGD-AT）在梯度攻击下表现优异，对 FGSM、PGD 和 C&W 攻击的防御准确率分别高达 96.10%、94.95% 和 95.05%，充分验证了 L_p 范数对抗性训练的有效性。然而，PGD-AT 对自适应遮蔽攻击（ $N = 5$, $R = 3$ ）的防御准确率低至 30.12%，与标准模型（34.33%）相比几乎没有提升。这一现象说明 PGD 对抗性训练几乎完全无法抵御遮蔽类攻击，其鲁棒性完全局限于 L_p 范数球内的扰动分布。

仅以遮蔽攻击训练的模型对梯度攻击的防御能力严重退化，如 Adaptive-Saliency-AT 在遮蔽攻击防御上取得了显著提升（自适应显著性遮蔽攻击 $N=5$ ：




图 4.27 Adaptive-Saliency-AT 与 Mix AT 综合性能雷达图对比

94.30%)，但对 FGSM 的准确率仅为 41.56%，对 PGD 和 C&W 则分别降至 4.78% 和 5.73%。IG 模型表现出同样的规律：Fixed-IG-AT 对 IG 遮蔽攻击防御准确率高达 97.34%，但对 FGSM 仅为 3.24%，对 PGD 和 C&W 更是降至 0%；Adaptive-IG-AT 对自适应 IG 遮蔽防御达 87.03%，但 PGD 防御仅 0.20%。这种防御能力的极端失衡在两种像素重要性计算方法的训练中一致呈现，揭示了单一攻击类型对抗性训练的局限：模型在训练中过度拟合特定攻击模式，导致对分布外攻击的鲁棒性急剧退化。

混合对抗性训练实现梯度防御与遮蔽防御的有效平衡。

Mix AT(Adaptive-Saliency+PGD) 策略在干净准确率 (98.91%)、梯度攻击防御 (FGSM: 94.51%, PGD: 92.87%, C&W: 92.81%) 和原始梯度显著性图防御 (自适应原始梯度显著性图 $N=5$: 80.65%) 三个维度上均表现均衡。IG 系列的混合训练同样有效：Mix AT(Adaptive-IG+PGD) 在干净准确率 (98.90%)、梯度防御 (PGD: 91.48%) 和 IG 遮蔽防御 (自适应 IG: 77.50%) 上取得了良好平衡，且对原始梯度显著性图也具有较强的泛化能力 (自适应显著性遮蔽: 76.06%)。两种混合训练策略均验证了将遮蔽攻击与梯度攻击相结合的训练范式的有效性。

对抗性训练对干净准确率的影响较小。

九种防御策略中，除 Fixed-IG-AT (95.75%) 略有下降外，其余策略的干净准确率均保持在 98% 以上，与标准模型 (99.00%) 差距极小。Fixed-IG-AT 的

干净准确率下降约 3 个百分点，可能是因为固定 IG 遮蔽的大面积遮蔽 ($k=9$) 在训练中过度破坏了图像的语义结构。总体而言，本文提出的遮蔽对抗性训练框架在提升鲁棒性的同时，对正常样本的分类性能影响有限，有效控制了鲁棒性-干净性的权衡代价。

4.4.3 遮蔽攻击与梯度攻击的相互抵消趋势

Duan 等人 [22] 指出， L_∞ 对抗性训练会导致模型决策依赖发生“特征不均等” (feature inequality) 现象，即少数像素的像素重要性显著放大，模型对显著像素的依赖性增强。该现象意味着遮蔽攻击与梯度类对抗性训练可能存在**相互抵消趋势**：针对遮蔽攻击，遮蔽对抗训练的鲁棒性高于标准模型，而梯度对抗训练 (PGD-AT、FGSM-AT) 反而低于（或与标准模型持平）；针对梯度类攻击，规律完全相反。本文实验中这一现象在 Saliency Map 遮蔽攻击下得到了清晰体现，但在 IG 遮蔽攻击下未呈现。具体数据汇总于表 4.8。

对于原始梯度遮蔽攻击，PGD-AT 的防御准确率（固定 $k=9$: 70.11%）略低于 Standard (71.19%)，自适应显著性遮蔽下亦然 (PGD-AT: 30.12% vs. Standard: 34.33%)，表明 PGD 对抗性训练不仅未能提升对显著性遮蔽的防御，反而使模型略微更加脆弱。这一“抵消效应”与 Duan 等人 [22] 发现的 L_∞ 对抗性训练导致像素重要性不均等 (inequality) 现象一致：PGD-AT 迫使模型将决策依据集中于极少数像素，一旦这些像素被遮蔽，模型即丧失判别能力。

然而，对于 IG 遮蔽攻击，上述抵消效应并未出现。PGD-AT 的固定 IG 遮蔽防御准确率 (49.17%) 大幅高于 Standard (28.64%)，提升超过 20 个百分点；自适应 IG 遮蔽下同样如此 (PGD-AT: 25.42% vs. Standard: 16.66%)。FGSM-AT 呈现相同趋势 (固定 IG: 54.14% vs. Standard: 28.64%)。

这一差异的原因可能在于两种像素重要性计算方法所识别的关键像素分布不同：PGD 对抗训练使模型决策依赖更集中于少量关键像素，而显著性图与积分梯度对这种集中模式的捕获能力存在差异。在评估对抗训练模型的遮蔽鲁棒性时，应同时使用多种像素重要性计算方法进行攻击，以获得更全面的防御能力评估。

表 4.8 遮蔽攻击与梯度攻击的相互抵消趋势（准确率%）

模型	遮蔽攻击				梯度攻击			
	Fix-Saliency	Adaptive-Saliency	Fix-IG	Adaptive-IG	FGSM	PGD	C&W	Clean
Standard	71.19	34.33	28.64	16.66	79.46	33.34	33.37	99.00
PGD-AT	70.11	30.12	49.17	25.42	96.10	94.95	95.05	99.30
FGSM-AT	73.73	33.90	54.14	25.55	95.68	90.64	90.83	99.20
Adaptive-Saliency-AT(N=5,R=3)	98.43	94.30	64.74	47.18	41.56	4.78	5.73	98.73
Adaptive-IG-AT (N=5,R=3)	98.36	92.02	90.42	87.03	39.01	0.20	0.24	98.48

4.4.4 两种像素重要性计算方法的可视化对比与像素重要性集中度量化

为更直观地理解上述差异化抵消效应的微观机制，本节对同一样本在 Standard 与 PGD-AT 两种模型上分别可视化 Saliency Map 方法与 IG 方法，并量化像素重要性集中程度指标，定义为像素重要性绝对值排名前 9 像素之和占像素重要性总和的比例：

$$\text{Concentration} = \frac{\sum_{i=1}^9 |a_{(i)}|}{\sum_{i=1}^{H \cdot W} |a_i|}, \quad (4.5)$$

其中 $a_{(i)}$ 表示按绝对值降序排列的像素重要性图第 i 个像素。集中度越高表示模型决策依赖的像素越少。在 4 个 MNIST 样本上的统计结果如表 4.9 所示。

表 4.9 两种像素重要性计算方法在 Standard 与 PGD-AT 模型上的集中度对比

像素重要性计算方法	Standard	PGD-AT	相对变化倍数
Saliency Map	0.064	0.157	$\times 2.47$
IG	0.253	0.281	$\times 1.11$

从表 4.9 可见两个关键现象：

PGD-AT 使 Saliency Map 像素重要性显著集中（2.47 倍）。标准模型上 Saliency Map 像素重要性相对分散（集中度 0.064），而 PGD-AT 训练后 Saliency Map 像素重要性集中度跃升至 0.157，与 Duan 等人 [22] 发现的“ L_∞ 对抗性训练导致像素重要性不均等（inequality）”现象一致。此时 PGD-AT 模型将决策依赖压缩到极少数像素，一旦这些像素被准确遮蔽，模型即丧失判别能力，因此 PGD-AT 对原始梯度显著性图的防御能力反而略低于 Standard（70.11% vs. 71.19%）。

PGD-AT 对 IG 的影响微弱 (1.11 倍)。IG 的集中度在 PGD-AT 上仅小幅上升 (0.253→0.281)，远低于 Saliency Map 像素重要性的变化幅度。这意味着 IG 在 PGD-AT 上相对偏离了真正决定模型预测的关键像素，这一变化使得基于 IG 的遮蔽攻击在 PGD-AT 上效力大幅下降。

第五节 参数敏感性分析

本节以自适应原始梯度遮蔽攻击为例分析自适应遮蔽攻击与防御策略中各关键参数对实验结果的影响，以指导实际应用中的参数选择。

4.5.1 遮蔽区域数参数分析

自适应遮蔽攻击中的最大遮蔽次数 N 直接决定攻击强度。结合表 4.3 的数据， N 参数对标准模型的影响规律如下： N 从 3 增至 10 时，准确率从 49.45% 下降至 15.95%，下降幅度陡峭。

图 4.29 展示了不同防御策略下 N 参数的影响。对于 Adaptive-Saliency-AT 模型，随着 N 增大，准确率仅略有下降 ($N=3$: 95.97%, $N=10$: 88.74%)，表明该模型对遮蔽区域数量具有良好的鲁棒性。Mix AT 模型在 $N=10$ 时准确率降至 54.70%，但仍远高于 PGD-AT (11.63%) 和标准模型 (15.95%)。

4.5.2 遮蔽半径参数分析

遮蔽圆形区域的半径 R 控制每个遮蔽区域的覆盖面积，直接影响单次遮蔽的效果。固定 $N=5$ 条件下，不同 R 值对标准模型准确率的影响呈现规律性变化： $R=2$ 时准确率为 49.15%， $R=3$ 时降至 34.33%， $R=4$ 时进一步降至 23.91%。结果表明，增大遮蔽半径能够提升攻击强度，但边际效益递减。

图 4.30 展示了不同防御策略下 R 参数的影响。Adaptive-Saliency-AT 在 $R=4$ 时仍能维持 88.11% 的准确率，显著优于 Mix AT (69.41%) 和标准模型 (23.91%)，表明该模型对遮蔽区域大小具有较强的鲁棒性。






图 4.28 Saliency Map 遮蔽攻击与 IG 遮蔽攻击在 Standard 与 PGD-AT 模型上的对比。第二、三行为 Saliency Map 方法热力图，可观察到 PGD-AT 模型上 Saliency Map 方法明显聚焦到笔画边缘的少数像素（不均等现象）；第四、五行为 IG 方法热力图，PGD-AT 模型上 IG 方法覆盖范围几乎未变甚至有分散趋势。

图 4.29 N 参数敏感性分析：不同防御策略下遮蔽区域数对准确率的影响 ($R = 3$)图 4.30 R 参数敏感性分析：不同防御策略下遮蔽半径对准确率的影响 ($N = 5$)

4.5.3 遮蔽颜色参数分析

遮蔽填充颜色是影响攻击效果的重要因素，在 MNIST 灰度图像中，颜色取值范围为 $[0, 1]$ （对应原始像素空间）。表 4.10 列出了在 Mix AT 模型上，采用黑色（ $c = 0$ ）、灰色（ $c = 0.5$ ）、白色（ $c = 1$ ）三种遮蔽颜色时，自适应遮蔽攻击（ $N = 5$ ， $R = 3$ ）的防御效果。

表 4.10 遮蔽颜色对 Mix AT 防御模型准确率的影响（自适应遮蔽 $N=5$ ， $R=3$ ）

遮蔽颜色	模型准确率（%）
黑色（ $c = 0$ ）	80.65
灰色（ $c = 0.5$ ）	77.88
白色（ $c = 1$ ）	54.77

实验结果显示，白色遮蔽块（ $c = 1$ ）对该模型的攻击效果最强，使准确率降至 54.77%，明显低于黑色遮蔽块（80.65%）和灰色遮蔽块（77.88%）。这是因为 Mix AT 在训练时使用黑色遮蔽块（ $c = 0$ ）作为对抗样本，模型对黑色遮蔽块已形成较强的适应性防御，而对白色遮蔽块这一分布外的遮蔽颜色抵抗力较弱。该现象提示了对抗性训练中颜色多样性的重要性：若训练时仅使用单一颜色的遮蔽样本，模型可能对其他颜色的遮蔽攻击产生防御盲区，在实际部署时应考虑引入多颜色遮蔽样本以增强颜色鲁棒性。

4.5.4 训练轮数分析

所有对抗性训练策略均在 50 个 epoch 内完成稳定收敛。图 4.31 展示了 Adaptive-Saliency-AT($N=5, R=3$) 的训练曲线。训练至第 50 个 epoch 时，训练损失收敛至 0.158，训练准确率达 90.35%，测试集干净准确率达 98.67%，表明模型已充分收敛且无过拟合现象。实验观察表明，对抗性训练的损失曲线通常在前 30 个 epoch 内快速下降，后 20 个 epoch 趋于平稳，50 个 epoch 的训练设置对本文所有防御策略均能保证充分收敛，无需进一步增加训练轮数以提升防御性能。




图 4.31 Adaptive-Saliency-AT($N = 5$, $R = 3$) 训练曲线: (a) 准确率随训练轮数变化; (b) 损失收敛曲线

第六节 迁移攻击鲁棒性分析

4.6.1 白盒攻击与迁移攻击对比

迁移攻击在黑盒场景下以替代模型生成对抗样本再迁移至目标模型，是检验真实鲁棒性的关键维度。本节以 Standard 为替代模型，在八种防御模型上对比白盒 (WB) 与迁移 (Tr) 准确率。

表 4.11 列出全部防御策略在 FGSM、PGD、C&W 下的白盒与迁移结果。

表 4.11 各防御策略在梯度类攻击下的白盒 vs 迁移准确率对比 (%，替代模型: Standard)

防御策略	Clean	FGSM-WB	FGSM-Tr	PGD-WB	PGD-Tr	CW-WB	CW-Tr
Standard (替代模型)	99.00	79.46	—	33.34	—	33.37	—
PGD-AT	99.30	96.10	98.23	94.95	98.09	95.05	98.98
FGSM-AT	99.20	95.68	98.33	90.64	98.34	90.83	99.10
Adaptive-Saliency-AT($N=5, R=3$)	98.73	41.56	95.38	4.63	93.98	5.76	96.57
Mix AT(Adaptive-Saliency+PGD)	98.91	94.51	97.89	92.87	97.69	92.81	98.56
Fixed-IG-AT	95.75	3.24	88.13	0.00	89.67	0.00	91.79
Adaptive-IG-AT	98.48	39.01	96.19	0.20	95.79	0.24	97.33
Mix AT(Fixed-IG+PGD)	98.53	93.50	97.40	91.70	97.44	91.70	98.15
Mix AT(Adaptive-IG+PGD)	98.47	98.11	98.48	98.09	98.45	98.07	98.50

表 4.12 汇总六种代表性防御策略在遮蔽攻击下的白盒、迁移准确率及两者差距，迁移样本统一由 Standard 生成。

从表 4.11 可以看出三类模型表现差异明显。PGD-AT 和 FGSM-AT 的白盒与迁移准确率都在 90% 以上，差距只有几个百分点。只用遮蔽攻击训练的模型

表 4.12 代表性防御策略在遮蔽类攻击下的白盒 vs 迁移准确率对比(%, 替代模型: Standard)

防御策略	遮蔽攻击类型	白盒	迁移	差距 (迁移-白盒)
Adaptive-Saliency-AT	Fixed-Saliency	98.43	95.15	-3.28
Adaptive-Saliency-AT	Adaptive-Saliency	94.30	91.96	-2.34
Mix AT(Adaptive-Saliency+PGD)	Fixed-Saliency	95.48	95.22	-0.26
Mix AT(Adaptive-Saliency+PGD)	Adaptive-Saliency	80.65	94.07	+13.42
Fixed-IG-Occlusion-AT	Fixed-IG	97.34	94.77	-2.57
Adaptive-IG-Occlusion-AT	Adaptive-IG	87.03	95.98	+8.95
Mix AT(Fixed-IG+PGD)	Fixed-IG	84.43	94.67	+10.24
Mix AT(Fixed-IG+PGD)	Adaptive-IG	59.23	93.64	+34.41
Mix AT(Adaptive-IG+PGD)	Fixed-IG	87.69	94.47	+6.78
Mix AT(Adaptive-IG+PGD)	Adaptive-IG	77.50	95.61	+18.11

(Adaptive-Saliency-AT、Fixed-IG-AT、Adaptive-IG-AT) 则反差极大: 白盒 PGD 和 C&W 准确率接近 0, 但迁移攻击下仍能维持在 90% 左右, 说明这些模型在自身梯度方向上仍易被白盒攻击攻破, 但 Standard 替代模型生成的对抗样本难以迁移到这些经过特殊训练的模型上。Mix AT 系列整体表现最好, 其中 Mix AT(Adaptive-IG+PGD) 的白盒 PGD (98.09%) 与迁移 PGD (98.45%) 高度一致, 且白盒结果反超 PGD-AT 的 94.95%, 是表现最稳定的策略。

表 4.12 的遮蔽攻击结果显示, 所有模型的迁移准确率都集中在 93%~96%, 说明遮蔽攻击的跨模型迁移性较强。值得注意的是部分模型出现”迁移高于白盒”的情况, 例如 Mix AT(Fixed-IG+PGD) 在 Adaptive-IG 攻击下白盒只有 59.23%, 迁移却达 93.64%, 差距 +34.41pp。这是因为 IG 方法在不同模型之间差异较大, 从 Standard 模型生成的迁移样本无法精准命中目标模型经训练加固的区域, 从而难以有效攻击目标模型。

综合两个表的数据, Mix AT(Adaptive-IG+PGD) 是最均衡的防御策略: 梯度攻击和遮蔽攻击下都能保持较高准确率, 且白盒与迁移结果接近, 鲁棒性最为可靠。相比之下, PGD-AT、FGSM-AT 对遮蔽攻击几乎毫无防御能力, 只用遮蔽攻击训练的模型则在白盒梯度攻击下表现极差, 均存在明显短板。

第七节 本章小结

本章在 MNIST 与 LeNet-5 上对所提遮蔽攻击与对抗性训练策略进行了系统实验评估，主要结论如下：

（1）自适应遮蔽攻击具备与主流梯度攻击相当甚至更强的攻击能力。

（2）对抗性训练存在明显的攻击特异性：仅以梯度攻击训练的模型对遮蔽攻击几乎无防御能力，仅以遮蔽攻击训练的模型对梯度攻击则严重退化，验证了混合训练的必要性。

（3）混合对抗性训练（Mix AT）能在梯度攻击与遮蔽攻击之间取得较好的平衡，干净准确率维持在 98% 以上，是综合实用性最强的防御方案。

（4）参数敏感性实验显示，遮蔽数量、半径与颜色均会显著影响攻击效果，为实际部署中的参数选择提供了参考。

第五章 总结与展望

第一节 工作总结

本文围绕基于像素重要性的遮蔽攻击与对抗性训练展开系统性研究，主要工作可归纳为以下四个方面。

（一）实现并对比了两种像素重要性分析方法的遮蔽攻击。本文同时实现了基于 Saliency Map 与基于 IG 的遮蔽攻击。前者仅需一次反向传播，计算代价低，适合嵌入对抗性训练在线生成攻击样本；后者通过路径积分获得更精确的关键像素定位，攻击强度更高但代价显著增加。

（二）设计了具备逐样本自适应能力的遮蔽攻击算法。本文实现的自适应遮蔽攻击在遮蔽数量与遮蔽半径构成的二维参数空间中逐步推进，一旦使模型误分类即终止搜索，兼顾攻击成功率与计算效率。

（三）提出了融合遮蔽攻击与梯度攻击的混合对抗性训练方法。针对单一攻击类型对抗训练泛化能力不足的问题，本文设计的 Mix AT 在每轮训练中同时引入 PGD 梯度对抗样本与基于像素重要性图的遮蔽对抗样本，使模型同时习得对两类异质扰动的鲁棒表示。Mix AT 在保持高干净准确率的前提下，对梯度攻击与遮蔽攻击均具备较好的防御能力，是兼顾实用性与全面性的平衡方案。

（四）构建了系统化的综合评估体系并揭示了若干关键规律。本文在 MNIST 与 LeNet-5 上完成了九种防御策略与七类攻击的对比实验，主要观察包括：单一攻击训练具有明显特异性、自适应遮蔽训练对同类遮蔽攻击防御最优、混合训练能实现跨类型平衡、Saliency Map 遮蔽与 IG 遮蔽在防御模型上呈现差异化抵消效应。这些规律为后续防御方案设计与鲁棒性评估方法提供了参考。

第二节 研究局限性

尽管取得了上述成果，本文仍存在以下局限。其一，实验仅在 MNIST 数据集与 LeNet-5 模型上进行，相关结论能否平稳迁移至彩色复杂图像数据集（如 CIFAR、ImageNet）和现代深层网络（如 ResNet、WideResNet）尚未得到验证。其二，遮蔽攻击在视觉上可感知，不符合传统对抗扰动的隐蔽性要求，其威胁模型更接近物理遮挡而非“不可察觉攻击”。其三，混合对抗性训练需同时生成两类对抗样本，训练时间更长，对计算资源要求较高，在资源受限场景中存在部署障碍。

第三节 未来研究方向

针对上述局限，未来工作可从以下几个方向展开。首先，将所提攻击与防御方法迁移至 CIFAR-10、ImageNet 等更复杂的数据集与 ResNet 等现代骨干网络，验证其通用性与可扩展性。其次，优化自适应搜索策略，例如引入二分搜索或借助轻量级预测网络估计每个样本的最优参数，进一步降低攻击的计算代价。第三，将混合训练的覆盖范围扩展至几何变换、频域、色彩扰动等更多攻击类型，构建面向多元威胁的统一防御框架。最后，从决策边界几何与特征鲁棒性角度对遮蔽攻击与混合训练的有效性提供理论分析，并结合自动驾驶、人脸识别、医学影像等安全关键场景探索实际部署路径，推动研究成果走向真实应用。

参考文献

- [1] Geoffrey E. Hinton, Simon Osindero, Yee-Whye Teh. A fast learning algorithm for deep belief nets. *Neural Computation*, 2006, 18(7): 1527–1554.
- [2] Yann LeCun, Yoshua Bengio, Geoffrey Hinton. Deep learning. *Nature*, 2015, 521(7553): 436–444.
- [3] Christian Szegedy, Wojciech Zaremba, Ilya Sutskever, et al. Intriguing properties of neural networks. In: *International Conference on Learning Representations (ICLR)*, 2014.
- [4] Alex Krizhevsky, Ilya Sutskever, Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In: *Advances in Neural Information Processing Systems (NeurIPS)*, 2012.
- [5] Kaiming He, Xiangyu Zhang, Shaoqing Ren, et al. Deep residual learning for image recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016: 770–778.
- [6] Kevin Eykholt, Ivan Evtimov, Earlene Fernandes, et al. Robust physical-world attacks on deep learning visual classification. In: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018: 1625–1634.
- [7] Alexey Kurakin, Ian J Goodfellow, Samy Bengio. Adversarial examples in the physical world. In: *Artificial intelligence safety and security*, 2018: 99–112.
- [8] Samuel G. Finlayson, John D. Bowers, Joichi Ito, et al. Adversarial attacks on medical machine learning. *Science*, 2019, 363(6433): 1287–1289.
- [9] Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, et al. Towards deep learning models resistant to adversarial attacks. In: *International Conference on Learning Representations (ICLR)*, 2018.
- [10] Ian J Goodfellow, Jonathon Shlens, Christian Szegedy. Explaining and harnessing adversarial examples. *arXiv preprint arXiv:1412.6572*, 2014.

-
- [11] Francesco Croce, Matthias Hein. Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks. In: International Conference on Machine Learning (ICML), 2020: 2206–2216.
 - [12] Tom B Brown, Dandelion Mané, Aurko Roy, et al. Adversarial patch. arXiv preprint arXiv:1712.09665, 2017.
 - [13] Florian Tramèr, Alexey Kurakin, Nicolas Papernot, et al. Ensemble adversarial training: Attacks and defenses. In: International Conference on Learning Representations (ICLR), 2018.
 - [14] Ali Shafahi, Mahyar Najibi, Mohammad Amin Ghiasi, et al. Adversarial training for free! In: 2019.
 - [15] Eric Wong, Leslie Rice, J Zico Kolter. Fast is better than free: Revisiting adversarial training. In: International Conference on Learning Representations (ICLR), 2020.
 - [16] Nicolas Papernot, Patrick McDaniel, Xi Wu, et al. Distillation as a defense to adversarial perturbations against deep neural networks. In: IEEE Symposium on Security and Privacy (SP), 2016: 582–597.
 - [17] Jeremy Cohen, Elan Rosenfeld, Zico Kolter. Certified adversarial robustness via randomized smoothing. In: International Conference on Machine Learning (ICML), 2019: 1310–1320.
 - [18] Rafael Müller, Simon Kornblith, Geoffrey E Hinton. When does label smoothing help? In: 2019.
 - [19] Karen Simonyan, Andrea Vedaldi, Andrew Zisserman. Deep inside convolutional networks: Visualising image classification models and saliency maps. arXiv preprint arXiv:1312.6034, 2013.
 - [20] Mukund Sundararajan, Ankur Taly, Qiqi Yan. Axiomatic attribution for deep networks. In: International Conference on Machine Learning (ICML), 2017: 3319–3328.
 - [21] Ramprasaath R Selvaraju, Michael Cogswell, Abhishek Das, et al. Grad-cam: Visual explanations from deep networks via gradient-based localization. In: Pro-

- ceedings of the IEEE International Conference on Computer Vision (ICCV), 2017: 618–626.
- [22] Ranjie Duan , Yuefeng Chen , Yao Zhu , Xiaojun Jia , Rong Zhang , Hui Xue. Inequality phenomenon in ∞ -adversarial training, and its unrealized threats. In: International Conference on Learning Representations(ICLR), 2023.
- [23] Yann LeCun, Léon Bottou, Yoshua Bengio, et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 2002, 86(11): 2278–2324.
- [24] Diederik P Kingma, Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [25] Nicholas Carlini, David Wagner. Towards evaluating the robustness of neural networks. In: *IEEE Symposium on Security and Privacy (SP)*, 2017: 39–57.
- [26] Narine Kokhlikyan, Vivek Miglani, Miguel Martin, et al. Captum: A unified and generic model interpretability library for pytorch. *arXiv preprint arXiv:2009.07896*, 2020.
- [27] Yann LeCun, Corinna Cortes, Christopher J. C. Burges. MNIST handwritten digit database. 2010.

致 谢

值此论文完成之际，谨向四年来所有给予我帮助、关怀与陪伴的师长、亲人和朋友致以最诚挚的谢意。

首先，我要衷心感谢我的指导老师王靖副教授。从论文选题、方案设计到实验推进与撰写修改，王老师始终给予我细致而专业的指导。每当我在研究中遇到困惑时，王老师总能以严谨的学术态度与开阔的研究视野指点迷津，并以极大的耐心包容我的不成熟与反复。王老师对学问的执着、对学生的尽责，将是我未来学习与工作中长久受用的榜样。

感谢南开大学软件学院四年来辛勤教导我的各位老师。是各位老师在职堂内外的讲授与言传身教，为我打下了较为系统的专业基础，也让我逐步理解了什么是科研与求真的态度。也感谢学院教务与行政老师在学习与生活中给予的种种支持。

感谢与我并肩走过这段时光的同学和朋友。无论是日常学习中的讨论，还是论文阶段彼此的鼓励与相互打气，都让我在压力最大的时刻仍能保持前行的勇气。那些一同度过的清晨与深夜，是大学生涯中最温暖的记忆。

特别感谢我的家人。父母一如既往的理解、支持与无言的关怀，是我求学路上最坚实的依靠。无论顺境逆境，他们始终是最深的牵挂与最大的力量。

最后，感谢南开大学。在这里度过的四年时光给予了我远不止专业知识的成长。”允公允能、日新月异”的校训将继续指引我前行。

由于本人学识有限，论文中不足之处在所难免，恳请各位老师批评指正。